
난임시술 배아 이미지 데이터

Data-Building Project in Embryo images from
IVF(in vitro fertilization)



건양대학교병원

**해당 자료는 AI-Hub에서 제공된 것으로,
저작권은 AI-Hub에 있으며,
원본 자료는 AI-Hub 웹사이트에서 확인하실 수 있습니다.**

[https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=1
&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&s
earchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORD
ER001&srchPagePer=60&srchDataRealmCode=REALM006&aihu
bDataSe=data&dataSetSn=71367](https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=1&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORDER001&srchPagePer=60&srchDataRealmCode=REALM006&aihubDataSe=data&dataSetSn=71367)

ABOUT THIS REPORT

개요

난임시술 과정에서 생성되는 배아 현미경 이미지(원본)와 타임랩스 배아 이미지, 그리고 임상데이터를 함께 구성한 학습 데이터입니다. 이미지 기반 정보와 시술·임상 정보가 환자/시술 단위로 연계되도록 구성되어, 배아 상태를 단일 이미지가 아니라 경과와 맥락 속에서 해석할 수 있습니다. 또한 기관별로 생성 환경이 다른 데이터를 동일한 구조로 정리하여, 다양한 환경에서 수집된 배아 이미지를 일관된 형태로 활용할 수 있도록 설계되었습니다.

데이터셋 목적

배아 선별이 숙련도에 따라 달라질 수 있는 한계를 보완하기 위해, 배아 이미지를 기반으로 객관적 평가(등급화) 및 임신 가능성 예측이 가능한 AI 모델 개발을 목표로 합니다. 특히 시술 과정에서 반복적으로 발생하는 판단 지점을 데이터로 표준화해, 배아 선택 과정의 일관성·재현성을 높이는 데 목적이 있습니다. 이를 통해 배아 선별·관리 과정의 효율을 높이고, 임신 성공률 향상 및 환자 부담(시간/비용/심리적 부담) 완화에 활용할 수 있도록 구성했습니다.

데이터 구축 과정

의료기관으로부터 배아 이미지와 임상정보를 수집한 뒤 비식별화를 수행하고, 이미지-임상정보 매칭 및 임상항목 정제를 거쳐 원천 데이터를 정리합니다. 이후 1차 라벨링을 수행하며, 항목 성격에 따라 일반 라벨(비전문 영역)과 전문 등급(전문 영역)을 분리해 구축합니다. 전문 등급 항목은 단일 작업자 판단으로 확정하지 않고, 다수 전문가 합의 방식으로 보강하여 라벨의 흔들림을 최소화한 뒤 최종 데이터셋을 완성합니다.

데이터 검수

검수는 이슈 기록-재작업-재검수(approve/reject) 흐름으로 운영되며, 객체누락/분류오류/영역오류/불필요 객체 등 주요 오류 유형을 기준으로 품질을 점검합니다. 검수 결과는 작업 단계로 다시 환류되어 동일 유형 오류가 반복되지 않도록 관리하고, 기준 미달 건은 재작업 대상으로 분리해 품질을 끌어올립니다. 또한 일반 작업자 검수 → 전문의 검수 → 배아 전문가 교차 검수로 단계적으로 품질을 보강하여, 학습에 적합한 수준의 정확도와 일관성을 확보합니다.



문의처

데이터에 대한 문의 사항은 다음 연락처로 연락주시기 바랍니다.

- 담당자명: 허진 ((주)카이헬스)
- 전화 : 0507-1302-9698
- E-mail : info@kaihealth.tech
- 홈페이지 : www.aihub.or.kr

● 데이터 포맷

- 데이터 포맷
 - 원천데이터: 배아 이미지(PNG, JPG)
 - 메타데이터: 임상정보(CSV)
 - 라벨링데이터(labels): 배아위치 바운딩 박스, 할구 폴리곤, ICM, TE 등급 등(JSON)
 - 라벨링데이터(meta): 라벨링 파일이름 정보(JSON)

원천데이터(PNG) 예시	라벨링데이터(JSON) labels 예시
	<pre>1- { 2- "objects": [3- { 4- "id": "b27ef448-e614-4848-8e21-6f4080990765", 5- "class_id": "2d4e8718-8011-4a09-9a05-3e27e48efcd8", 6- "class_name": "embryo", 7- "annotation_type": "box", 8- "annotation": { 9- "coord": { 10- "x": 227.96911089845395, 11- "y": 27.00763715136829, 12- "width": 157.26125482617886, 13- "height": 162.42949523938955 14- }, 15- "meta": { 16- "z_index": 0, 17- "visible": true, 18- "alpha": 1, 19- "color": "#000000" 20- } 21- }, 22- "properties": [] 23- }, 24- { 25- "id": "a0edd073-64b3-4516-b091-55460e1b8faa", 26- "class_id": "4d4a9a1a-f31e-41ee-b362-058f131fd857", 27- "class_name": "cell", 28- "annotation_type": "polygon", 29- "annotation": { 30- "multiple": true, 31- "coord": { 32- "points": [33- { 34- "x": 261.35082043159986, 35- "y": 123.62416055780709, 36- ... 37- }, 38- { 39- "x": 261.35082043159986, 40- "y": 123.62416055780709 41- } 42-] 43- }, 44- "meta": { 45- "z_index": 1, 46- "visible": true, 47- "alpha": 1, 48- "color": "#A0E057" 49- } 50- }, 51- "properties": [] 52- } 53-], 54- "properties": [] 55- }</pre>
라벨링데이터(이미지) 예시	라벨링데이터(JSON) meta 예시
	<pre>1- { 2- "data_key": "10001_d5_20210715_1.jpg", 3- "dataset": "0902-batch08", 4- "image_info": {"width": 4032, "height": 3024}, 5- "label_id": "7a8376be-ab2f-4834-b302-7fd174a5819e", 6- "label_path": ["Labels/7a8376be-ab2f-4834-b302-7fd174a5819e.json"], 7- "last_updated_date": "2022-11-09T00:37:47.426507Z", 8- "tags": [{"id": "59da9b16-757e-40ba-bd7d-a104ae96f507", 9- "name": "moved_0913"}, 10- {"id": "f1f1c6da-14e2-4e7f-9d97-eee708bc99d9", "name": "DS"}, 11- {"id": "1ef6b135-6485-41b3-b195-b5a2e7f35ffc", "name": "microscope"}, 12- {"id": "e21b9b90-b625-4cdc-ba15-64090b206f07", "name": "none"}, 13- {"id": "e14e9940-94aa-442a-a38a-eabd4c347969", "name": "3rd"}, 14- {"id": "e086ca25-3087-4c85-afe6-6121f53aacc8", "name": "301_intergrated"}, 15- {"id": "15006e88-eba2-45f5-bd90-ad7b408c92a4", "name": "aju"}, 16- {"id": "693ecb8a-76d3-4cb2-b8d4-37d4912b7335", "name": "fin_check_completed"}, 17- {"id": "f4c840be-611e-4da1-bd4f-05d527940ba3", "name": "second_check_1116"}, 18- {"id": "5a6296ec-4b24-491f-a748-fdec0385d0be", "name": "results_fin_1117"}], 19- "work_assignee": "snlee6555@hmail.net", "status": "SUBMITTED"} 20- }</pre>

메타데이터 (JSON)													
환자의 임상정보													
Patient.ID	Embryo.ET	Embryo.OI	Patient.Fer	Patient.Ma	Patient.Coi	Cycle.G-sa	Cycle.Egg	Cycle.Mil	r Cycle.2PN	Cycle.ET	n Cycle.Cam	Cycle.Micr	stop char
20001	20211209	20211206	40	40	4	0	3	3	2	2	16	16 h	
20001	20220506	20220503	41	41	4	0	2	2	2	2	16	16 h	
20003	20201123	20201120	31	37	6	0	6	5	5	2	16	16 h	
20003	20180318	20180315	29	35	6	0	8	5	3	2	16	16 h	
20004	20180817	20180814	28	48	1	0	14	11	10	2	16	16 h	
20004	20180619	20180616	28	48	1	0	4	2	2	2	16	16 h	
20007	20170613	20170610	38	40	3	0	4	3	3	2	16	16 h	
20007	20180514	20180511	39	41	3	0	2	2	2	1	16	16 h	
20007	20181231	20181228	39	41	3	0	6	4	2	2	16	16 h	
20009	20180614	20180611	34	35	6	0	2	2	2	2	16	16 h	
20010	20180428	20180425	40	41	3	0	3	3	3	1	16	16 h	
20011	20130626	20130623	31	34	8	0	6	5	6	2	16	16 h	
20018	20161006	20161003	34	38	7	0	4	4	2	1	16	16 h	
20018	20161204	20161201	34	38	7	0	5	2	2	2	16	16 h	
20019	20150203	20140729	35	35	7	0	8	7	8	1	16	16 h	
20019	20140801	20140729	35	35	7	0	8	7	8	2	16	16 h	
20021	20140129	20140126	35	36	1	0	5	2	4	2	16	16 h	
20027	20130620	20130617	39	37	5	0	5	3	5	2	16	16 h	
20028	20130701	20130628	37	41	3	0	6	2	5	2	16	16 h	
30001	20210508	20210505	32	100000	100000	0	5	1	3	2	21	21 h	
30002	20210711	20210708	38	100000	100000	0	4	3	3	3	21	21 h	
30006	20211016	20211013	37	100000	100000	0	8	6	3	3	21	21 h	
30007	20211122	20211119	30	100000	100000	3	7	5	6	2	21	21 h	
30008	20211125	20211122	39	100000	100000	0	5	4	3	3	21	21 h	
30010	20210430	20210331	39	100000	100000	0	23	18	17	3	21	21 h	
30011	20210528	20210305	36	100000	100000	1	9	9	7	3	21	21 h	
30012	20210603	20210331	39	100000	100000	0	23	18	17	3	21	21 h	
30014	20210629	20210329	31	100000	100000	0	9	9	7	2	21	21 h	
30015	20210720	20210401	37	100000	100000	0	17	15	12	2	21	21 h	
30016	20210730	20210702	42	100000	100000	0	13	10	10	2	21	21 h	
30017	20210817	20210716	37	100000	100000	1	10	7	6	3	21	21 h	

그림1| 전자 의료 기록 데이터 예시

● 데이터 종류

- 현미경 배아 촬영 원본 이미지

- 배아가 성숙하는 과정 중 일 째, 또는 5일 째 배아의 주입, 동결, 폐기 여부를 결정하기 위하여 난임 전문 병원에서 촬영하는 이미지
- 한 번의 난임치료 주기에서 다수의 배아가 발생할 수 있기 때문에, 1개의 배아가 촬영되는 경우도 있고, 한 번에 여러 개의 배아가 촬영된 경우도 있습니다.
- 이미지 포맷은 병원 별로 상이하나, 주로 JPG PNG 파일로 구성 됩니다.

- 타임랩스 촬영 배아 이미지

- 배양기 내에 지속작동형 현미경을 장착하여 배아의 발달 단계를 실시간으로 관찰, 녹화하고 현상을 기록할 수 있는 장치를 사용하여 이미지를 추출합니다.
- 3일 배양 배아: 수정작업 이후 66-68시간 사이 배아 사진 이용
- 5일 배양 배아: 수정작업 이후 106-108시간 사이 배아 사진 이용

● 어노테이션 포맷

표1| 라벨링 데이터(meta)

구분	속성명	타입	필수여부	설명	범위	비고
	1-1	data_key	string	Y	데이터 경로	
	1-2	dataset	string	Y	작업 세트	
	1-3	image_info	object	Y	이미지 정보	
	1-4	width	number	Y	이미지 너비	
	1-5	height	number	Y	이미지 높이	
	1-6	label_id	string	Y	라벨링 파일 이름	
	1-7	label_path	array	Y	라벨링 파일 경로	
	1-8	last_updated_date	string		마지막 수정 일자	
	1-9	tags	array		이미지와 관련된 정보	
	1-10	id	string		이미지 정보의 키값	
	1-11	name	string		이미지 정보의 실제 값	
	1-12	work_assignee	string		작업 할당 정보	
	1-13	status	string		작업 상태	

표2| 라벨링 데이터(labels)

구분	속성명	타입	필수여부	설명	범위	비고
1	objects	object	Y	데이터셋 정보		
	1-1	id	string	Y	객체 아이디	
	1-2	class_id	string	Y	클래스 아이디	
	1-3	tracking_id	int	N	어노테이션 생성 번호	
	1-4	class_name	string	Y	클래스 명	zona_outer, zona_inner, TE, ICM, fertilized_egg, cell, fragmentation
	1-5	annotation_type	string	Y	어노테이션 형태	polygon, box
	1-6	annotation	object	N	어노테이션 정보	
	1-7	multiple	boolean	Y		true, false
	1-8	coord	object	Y	어노테이션 좌표	
	1-9	points	object	Y	어노테이션 실제 좌표값	
	1-10	meta	object	N	어노테이션 속성과 관련한 정보	

	1-11	z_index	number	N	어노테이션의 계층 (이번 배아 과제와는 상관없음)		
	1-12	visible	boolean	N	어노테이션 시각화 설정		
	1-13	alpha	number	N	어노테이션 투명도 설정		
	1-14	color	string	N	어노테이션 색상		
	1-15	properties	list	N	어노테이션의 속성		
	1-16	fertilized_egg_id	number	Y	수정란 아이디값		
	1-17	x	number	N	바운딩박스 x좌표		
	1-18	y	number	N	바운딩박스 y좌표		
	1-19	width	number	N	바운딩박스 길이		
	1-20	height	number	N	바운딩박스 높이		
	1-21	type	string	N			
	1-22	property_id	string	N	어노테이션 아이디값		
	1-23	property_name	string	Y	등급 속성		
	1-24	option_id	string	N	등급 아이디값		
	1-25	option_name	string	Y	등급		
	1-26	cell_count	number	Y	셀 수		
	1-27	cell_circumference	array	Y	cell 둘레		
	1-28	zona_inner_area	number	Y	zona_inner 면적		
	1-29	fragmentation_area	number	N	fragmentation 면적		
	1-30	fragmentation_percentage	number	N	Cell 면적 대비 fragmentation 면적 비율		
	1-31	categories	object	N	fertilized egg 값		
	1-32	properties	array	N	Grade 등급 값		

표3| 메타 데이터(임상정보)

항목명	타입	필수여부	비고
Patient.ID	string	Y	환자번호
Embryo.ET date	string	Y	배아이식일자
Embryo.OPU date	string	Y	난자채취일자
Patient.Femaleage	string	Y	여성나이
Patient.Maleage	string	N	남성나이
Patient.Cause	string	N	난임원인
Cycle.G-sac	string	Y	임신여부
Cycle.Egg no	string	Y	총 난자 수
Cycle.MII no	string	Y	성숙 난자 수
Cycle.2PN no	string	Y	수정 난자 수
Cycle.ET no	string	Y	배아 이식 개수
Cycle.Camera	string	Y	배아 촬영 카메라
Cycle.Microscope	string	Y	배아 촬영 현미경
stop character	string	Y	항목명 끝을 알리는 문자

● 데이터 구성

● 데이터 폴더 구조




그림2 데이터 폴더 구조(1)




그림3| 데이터 폴더 구조(2)

● 라벨링 항목


구분	데이터 구분 및 설명	현미경 데이터	타임랩스 데이터	라벨링 항목
D3 (3일차 배아)	난자 채취 후 3일차인 배아를 뜻하며, 일반적으로 8 cell(알구)를 가지는 것이 특징입니다. 알구 수는 배아의 발달 속도에 따라 그 수가 다르지만 오차범위 2개까지 정상배아로 분류함에 따라 최소 6개 ~ 최대 10개 알구를 가진 배아만 라벨링하는 범위에 포함됩니다.			zona_outer
				zona_inner
				cell
				fragmentation
D5 (5일차 배아)	난자 채취 후 5일차인 배아를 뜻하며, hatching 단계 전인 blastocyst 단계에 있는 데이터만 라벨링하는데 해당됩니다. ICM의 형상이 일반적으로는 둥글지만, 발달하는 모습이 여러 형태로 발견되므로 나타나는 ICM영역을 TE와 분리하여 정확히 라벨링하는것이 중요합니다.			zona_outer
				zona_inner
				TE
				ICM

그림4| 라벨링 항목

● 데이터 구축 규모

표4| 데이터 폴더 구조

과제번호	과제명	데이터 유형	데이터 설명	데이터 건수
27	배아 이미지 데이터	원천데이터(PNG,JPG)	원본이미지	14,989
		라벨링데이터(JSON)	labels	14,989
			meta	14,989
		메타데이터(JSON)	임상정보	8,559

● 데이터 분포

● 다양성(통계)

표5| 연령대/임신 여부 분포

항목명	속성명	비율
산모 연령대별 분포	0~10	0.02%
	10~20	0.02%
	20~30	6.46%
	30~40	77.63%
	40~50	15.75%
	기타	0.22%
임신 여부 분포	임신	49.54%
	비임신	50.29%

● 다양성(요건)

표6| 연령대/임신 여부 분포

항목명	속성명	비율
현미경 이미지 배아 촬영 일자별 분포	3일	64.13%
	5일	35.87%
타임랩스 이미지 배아 촬영 일자별 분포	3일	54.91%
	5일	45.09%
배아 단계별 이미지 분포	1	3.81%
	2	9.40%
	3	17.63%
	4	27.41%
	5	23.67%
	6	18.07%

● 원시데이터 특성

- 대상 분류
 - 현미경과 타임랩스 이미지로 구성되어 있습니다.
 - 현미경: D3/D5
 - 타임랩스: D3/D5
- 제약 조건
 - 배아의 형태를 알아보기 힘든 경우에 일부 제약이 발생합니다.
- 속성
 - 속성은 정제 후에도 달라지지 않습니다.

● 기타 정보

- 포괄성

배아 단계별 이미지 분포	1	3.81%
	2	9.40%
	3	17.63%
	4	27.41%
	5	23.67%
	6	18.07%

- 독립성
 - 개인정보를 식별할 수 있는 환자번호의 비식별화를 통해서 민감정보를 보호합니다.
 - 이미지 상에 나타난 환자 정보도 "잘라내기"를 통하여 민감정보를 보호합니다.
- 유의사항
 - 데이터 활용 시 임상데이터 1개에 여러 개의 이미지작 있는 경우도 있으니 참고 바랍니다.

● 데이터 구축

● 데이터 구축 개요

(가) 원시 데이터 수집 및 환자 정보 비식별화

- 병원으로부터 데이터를 수집하고 환자정보를 비식별화 합니다.

(나) 임상 정보 매칭

- 이미지 데이터와 임상정보의 매칭 여부를 체크합니다.

(다) 임상정보 데이터 정제 프로세스

- 임상정보의 속성(항목)별 유효성을 검증합니다.

(라) 이미지 데이터 가공 프로세스

- 클라우드 워커를 통한 1차 라벨링을 실시합니다.
- 워커에 의한 라벨링을 전문가가 추가적으로 검사합니다.

(마) AI 모델학습 및 유효성 검증 프로세스

- 라벨링된 데이터로 모델을 학습하고 유효성을 검증합니다.

● 데이터 구축 유의사항

- 개인을 식별할 수 있는 환자정보는 비식별화 합니다.

● 수집 및 정제

● 원시데이터 선정

(가) 현미경 배아 촬영 원본 이미지

- 배아가 성숙하는 과정 중 3일 짜 또는 5일 짜 배아의 주입, 동결, 폐기 여부를 결정하기 위하여 난임 전문 병원에서 촬영하는 이미지입니다.
- 한 번의 난임 치료 주기에서 다수의 배아가 발생할 수 있기 때문에, 1개의 배아가 촬영되는 경우도 있고, 한 번에 여러 개의 배아가 촬영되는 경우도 존재합니다.
- 이미지 포맷은 병원별로 상이하나, 주로 JPG, PNG 파일로 구성되어 있습니다.

(나) 타임랩스 촬영 배아 이미지

- 타임랩스 시스템: 배양기 내에 지속작동형 현미경을 장착하여 배아의 발달 단계를 실시간으로 관찰, 녹화하고 현상을 기록할 수 있는 장치입니다. 원하는 시간대의 사진을 하나씩 추출 가능하게 설계되어 있습니다.
- 배아가 성숙하는 과정을 저속촬영한 동영상에서 3일째 혹은 5일째에 해당하는 스틸컷 이미지를 추출 합니다.
- 3일 배양 배아: 수정작업 이후 66-68 시간 사이 배아 사진 이용
- 5일 배양 배아: 수정작업 이후 106-108 시간 사이 배아 사진 이용

(다) 임상데이터

- AI 모델 학습을 위한 임신여부 뿐만 아니라, 산모의 컨디션을 추정할 수 있는 총 난자수나 성숙된 난자 수 등을 이용하여 모델링이 가능합니다.

표기 임상데이터

항목명	타입	필수여부	비고
Patient.ID	string	Y	환자번호
Embryo.ET date	string	Y	배아이식일자
Embryo.OPU date	string	Y	난자채취일자
Patient.Femaleage	string	Y	여성나이
Patient.Maleage	string	N	남성나이
Patient.Cause	string	N	난임원인
Cycle.G-sac	string	Y	임신여부
Cycle.Egg no	string	Y	총 난자 수
Cycle.MII no	string	Y	성숙 난자 수
Cycle.2PN no	string	Y	수정 난자 수
Cycle.ET no	string	Y	배아 이식 개수
Cycle.Camera	string	Y	배아 촬영 카메라
Cycle.Microscope	string	Y	배아 촬영 현미경
stop character	string	Y	항목명 끝을 알리는 문자

● 수집 절차

(가) 원시데이터의 획득 방안(10개 의료기관)

- 원시데이터 수집, 획득을 위하여 기관윤리심의위원회(Institutional Review Board, IRB)를 통해 후향적 데이터 수집에 대한 동의면제연구임을 확인하며, 기관데이터심의위원회(BigData Review Board, BRB)가 존재하는 의료기관의 경우에는 데이터 추출 계획 및 프로세스에 대해 심의를 수행합니다.
- 데이터 획득 참여기관의 연구자들이 영상데이터와 임상데이터를 수집합니다.
- 원시데이터를 보유한 10개 의료기관에서는 보유한 전자의무기록(ElectronicMedicalRecord, EMR) 및 정보시스템으로부터 임상 정보(환자 정보, 배아 정보, 주기 정보) 테이블을 csv 포맷으로 생성 합니다.
- 필수여부가 yes인 항목들은 모두 데이터 수집을 수행하며, 필수여부가 no인 항목들은 존재하는 경우에만 값을 기입합니다.
- 배아 이미지 데이터는 각 기관에서 사용하고 있는 데이터 포맷 (e.g., JPG, PNG, TIFF,PDF) 등 으로 저장합니다.

(나) 원시데이터의 획득 지원 방안(10개 의료기관)

- 원시데이터 수집을 담당하는 카이헬스는 각 10개 병원에서 추출하는 임상 정보 데이터 항목에 대한 상세 내역을 작성하고, 데이터 추출을 담당하는 사업 참여자에게 해당 내용을 교육합니다.
- 이미지 데이터에 대한 정제 및 라벨링을 수행하는 SuperbAI는 라벨링에 적합한 데이터 해상도, 수준을 정의하고 이에 대해 각 의료기관에 해당 내용을 교육합니다.
- 사업에 참여하는 10개 의료기관에서 원시데이터를 추출하는 과정에서 발생하는 문의사항들을 카이헬스에서 일괄 취합하여 대응합니다.
- (주)피트케어의 csv 형태 데이터 수집 도구를 활용하여 각 기관의 원시데이터를 수집합니다.

(다) 획득 시 고려사항

- 데이터 획득 대상, 획득 방법이 법·제도를 저촉하거나 사회 윤리에 어긋나지 않도록 합니다.
- IRB 승인을 얻은 후에 모든 데이터를 획득합니다.
- 개인정보 및 사생활 보호가 필요한 항목 획득 시 정제 과정에서 다음과 같이 처리합니다.
 - 수치형 데이터: 데이터 범주화
 - 텍스트 데이터: 이름, 민감정보, 키워드 데이터 변화 등
 - 이미지 데이터: 모자이크·블러 처리, 크롭(자르기) 등

(라) 데이터 다양성 확보

- 인공지능 학습모델이 현실을 잘 반영하고 본래의 구축 목적을 달성할 수 있도록, 획득하는 데이터가 일부 범주에만 치우치지 않고 가능한 다양한 집단과 수준이 포함될 수 있도록 구성합니다.

(마) 원시 데이터 획득에 대한 생명윤리법 검토

- 해당 연구는 사업 시작일자 기준으로 이미 후향적으로 발생한 데이터를 사용하므로 생명윤리 및 안전에 관한 법률(이하 생명윤리법) 제16조 3항의 서면동의 면제 요건을 충족함을 입증합니다.
- 연구계획서와 생명윤리법 제16조 3항에 따라 동의면제가 필요한 사유와 근거를 제출하고 이를 통해 IRB 동의면제 심의를 획득해야 합니다.

생명윤리 및 안전에 관한 법률(이하 생명윤리법) 제16조 제1항, 3항

㉠ 인간대상연구자는 인간대상연구를 하기 전에 연구대상자로부터 다음 각 호의 사항이 포함된 서면 동의(전자문서를 포함한다. 이하 같다)를 받아야 한다.

1. 인간대상연구의 목적
2. 연구대상자의 참여 기간, 절차 및 방법
3. 연구대상자에게 예상되는 위험 및 이득
4. 개인정보 보호에 관한 사항
5. 연구 참여에 따른 손실에 대한 보상
6. 개인정보 제공에 관한 사항
7. 동의의 철회에 관한 사항
8. 그 밖에 기관위원회가 필요하다고 인정하는 사항

㉡ 제1항에도 불구하고 다음 각 호의 요건을 모두 갖춘 경우에는 기관위원회의 승인을 받아 연구대상자의 서면동의를 면제할 수 있다. 이 경우 제2항에 따른 대리인의 서면동의를 면제하지 아니한다.

1. 연구대상자의 동의를 받는 것이 연구 진행과정에서 현실적으로 불가능하거나 연구의 타당성에 심각한 영향을 미친다고 판단되는 경우
2. 연구대상자의 동의 거부를 추정할 만한 사유가 없고, 동의를 면제하여도 연구대상자에게 미치는 위험이

그림5| 생명윤리법 제16조 제1항, 3항

(바) 원시데이터 비식별화/가명화에 대한 보건의료데이터활용 가이드라인 검토

- 2021년 1월 28일 보건복지부와 개인정보보호위원회에서 발간한 '보건의료 데이터 활용 가이드라인'에 따르면, 본 사업에서 발생하는 개인정보를 적절히 가명처리하여 생성된 가명정보는 통계작성, 과학적 연구, 공익적 기록 보존 등을 위하여 정보주체의 동의 없이 가명정보를 처리할 수 있습니다.
- 가이드라인에 따라, 개인식별자는 모두 구축 데이터에 대한 새로운 일련번호(환자ID)로 대체합니다.
- 수집하는 환자 정보 중 산모와 정자기증자의 생일은 일자를 삭제하여 연도와 월 정보만 남깁니다.

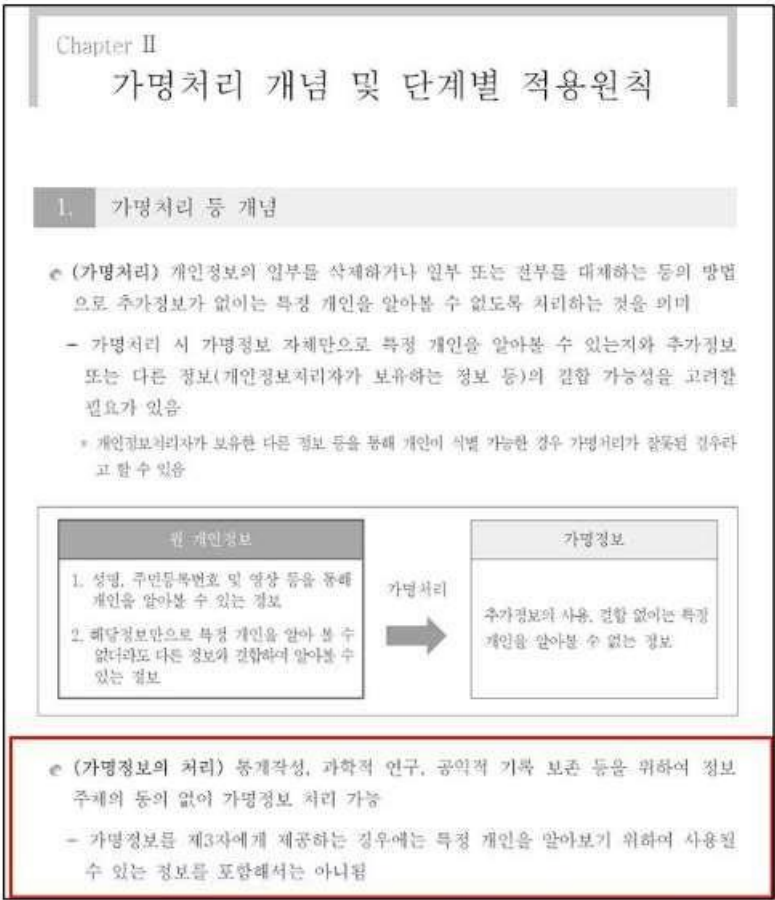


그림6 보건 의료데이터활용 가이드라인 - 가명처리의 개념과 가명정보의 처리

(사) 임상데이터 수집 절차



그림기 임상데이터 수집 절차

(아) 원시데이터 수집 절차(이미지)

- 각 병원에서 이미지 데이터를 수집합니다.
- 임상 정보와 이미지 데이터를 연결하기 위한 메타데이터를 생성하고, 이에 대한 가이드라인은 카이헬스와 SuperAI가 함께 수립하여 각 의료기관에 매뉴얼을 제공합니다.
- 이미지 데이터를 SuperAI의 판독시스템으로 업로드합니다.

(자) 데이터 수집 저장소



그림8 데이터 수집 저장소

(차) 데이터 수집 도구

- 임상데이터는 IRB 승인 후 난임 레지스트리(.csv) 혹은 EMR에서 획득합니다.
- 이미지 데이터는 기관마다 저장된 현미경 배아 이미지와 타임랩스 이미지를 획득합니다.

NO	Patient ID	성명	생년월일	성별	병원명	등록일자	등록시간	등록기관	등록일자	등록시간
1	00101	김민준	2000-12-01	남	서울대병원	2021-12-01	10:00	서울대병원	2021-12-01	10:00
2	00102	김민준	2000-12-02	남	서울대병원	2021-12-02	10:00	서울대병원	2021-12-02	10:00
3	00103	김민준	2000-12-03	남	서울대병원	2021-12-03	10:00	서울대병원	2021-12-03	10:00
4	00104	김민준	2000-12-04	남	서울대병원	2021-12-04	10:00	서울대병원	2021-12-04	10:00
5	00105	김민준	2000-12-05	남	서울대병원	2021-12-05	10:00	서울대병원	2021-12-05	10:00
6	00106	김민준	2000-12-06	남	서울대병원	2021-12-06	10:00	서울대병원	2021-12-06	10:00
7	00107	김민준	2000-12-07	남	서울대병원	2021-12-07	10:00	서울대병원	2021-12-07	10:00
8	00108	김민준	2000-12-08	남	서울대병원	2021-12-08	10:00	서울대병원	2021-12-08	10:00
9	00109	김민준	2000-12-09	남	서울대병원	2021-12-09	10:00	서울대병원	2021-12-09	10:00
10	00110	김민준	2000-12-10	남	서울대병원	2021-12-10	10:00	서울대병원	2021-12-10	10:00

그림9 데이터 수집 장소 및 저장방안

● 정제 방안

- 원시 데이터를 중복, 유효성, 비매칭 조정 작업을 통해 표준화된 데이터로 조정합니다.



그림10| 데이터 정제 방안

● 정제 절차

- 중복데이터의 제거: 사전에 배정하여 수집된 가상환자 번호를 기준으로 합니다.
- 개인 식별정보 포함 여부 확인: 비식별화/가명화대상 항목을 체크하여 점검합니다.
- 이미지 데이터의 영역 자르기: 이미지 데이터에 개인을 식별할 수 있는 정보가 존재하는지 점검하고, 해당 영역을 자릅니다.
- 데이터의 유효성 확인: 숫자에 해당하는 정보의 유효범위를 점검합니다.
- 비매칭 체크: 임상 정보의 세 가지 ID인 환자 ID, 배아 ID, 주기 ID에 매칭이 되지 않는 이미지 데이터를 점검합니다. (예시. 배아 촬영 이미지는 있는데 연결되는 주기정보가 없는 경우, 배아 정보는 존재하는데 연결되는 배아 촬영 이미지가 없는 경우 등)



그림11| 데이터 정제 도구

● 가공 및 검사

● 가공(라벨링) 절차

- 시스템/프로그래밍을 활용하여 원시데이터에서 입수한 정보(수집 장소, 일시, 환자번호 등)를 기계적으로 자동 입력합니다.
- 의료 데이터의 전문성 확보를 위해 데이터 가공을 전문 (영역 라벨링) 영역과 비전문(등급 분류) 영역으로 나누어 2-track 방식으로 라벨링 진행 후 취합합니다.
 - (1st track: 비전문 영역) 의료 전문가(배아 전문가) 지도 하 라벨링 전문가(최소 6개월 이상 근무자)를 투입하여 정교한 GT를 구축하여 구축된 데이터에 특화된 Custom AI를 생성합니다.
 - Custom AI를 활용하여 AI Labeling으로 1차 가공 진행 후 클라우드 소싱 라벨링으로 AI Labeling 결과 중 오류 사항을 중점적으로 작업합니다.
 - 전문 작업자가 2차 검수 진행하며 오류 발견 시 피드백과 함께 반력합니다.
 - 의료 전문가(배아 전문가)가 최종 검수를 진행하여 데이터 품질을 확보합니다.
 - (2nd track: 전문영역) ICM, TE 등급의 경우 의료 도메인에 대해 전문성을 갖춘 배아 전문가 3인 이상이 모여 Consensus Labeling을 통해 가공을 진행합니다.
 - 전문가가 판독 시 이상 데이터에 대해서는 소견을 기재하여 향후 재라벨링을 수행합니다.
- 검수 완료된 전문 영역과 비전문 영역 데이터를 취합하여 하나의 라벨링 데이터로 구성합니다.
- 라벨링 데이터 대상으로 자체적으로 의미적 검사와 구문적 검사를 수행하여 데이터 품질을 확보합니다.
- 메타 데이터 입력-가공-검수-검증 일련의 과정(Cycle) 종료 후 이슈 사항 파악하여 반영하며 이후 과정을 반복하여 데이터를 구축합니다.

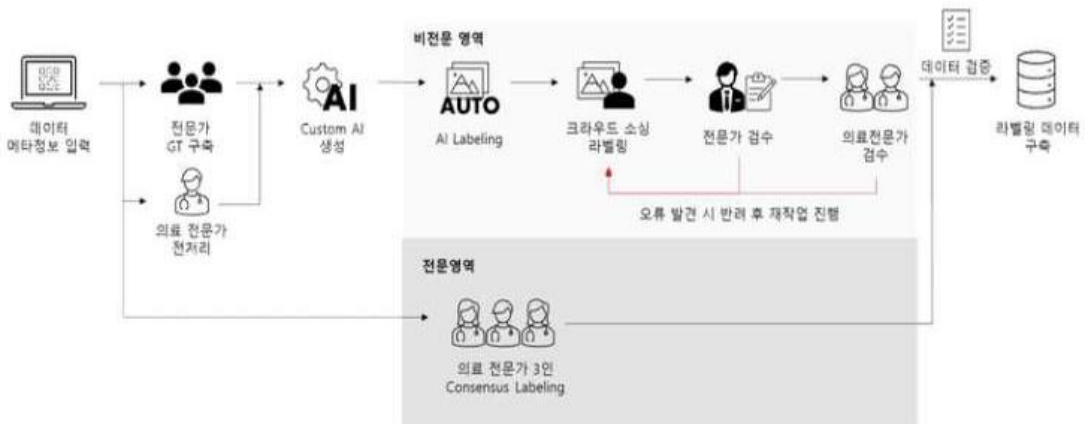


그림12| 데이터 가공 프로세스

● 가공(라벨링) 기준

- 10개 병원에서 수집된 배아 데이터의 정제과정을 통해 확보된 원천데이터에 대해 D3(3일차 배아), D5(5일차 배아)를 구분, 제시하기 위해 최적화된 카테고리 설정을 합니다.
- Microscope, Timelapse로 분류되는 데이터셋의 유연한 활용을 위해 다양한 객체 가공 및 작업유형으로 데이터를 가공합니다.
- 라벨링 진행방법/평균 예상 객체(Image 당 최소 1개~2개 작업)
 - * 작업자는 배아 발달단계를 확인하여 이미지를 분류(Classification)
 - Cleavage, Morula, Blastocyst, Hatching or Hatched Blastocyst
 - 1장의 이미지에서 여러개의 배아가 있을 경우, 예외 케이스를 제외한 모든 배아 분류 선택합니다.
 - * Morula를 제외한 배아 이미지는 라벨링(Box, Polygon) 작업 진행
 - Hatching or Hatched Blastocyst 같은 의료 지식이 필요한 데이터는 전문의 작업자가 직접 라벨링합니다.
 - * Blastocyst 단계 이상의 배아인 경우, bLstage, TE_grade, ICM_grade 등급 체크(단, 해당 작업 단계는 전문의 작업자만 시행)

Annotation Type	Division	Display Color	Class	Description
Polygon Segmentation	공통class		*zona_outer	수정란(배아)의 투명대 바깥쪽 경계를 뜻하며, 일반적으로 둥그란 모양이지만 주변 파편은 무시하고 라벨링합니다. 하나의 배아는 하나의 투명대만 가집니다.
			*zona_inner	할구나 ICM, TE와 같은 세포들을 둘러싼 영역으로 수정란(배아)의 투명대 안쪽 면적을 뜻합니다. outer보다 상대적으로 명확한 경계를 갖고 있으나, 간혹 경계가 불분명한 경우 할구 및 세포들을 감싸는 원형으로 라벨링합니다.
	Day3 (3일차)		*cell	수정란이 분열하여 생성된 세포. 세포(할구)는 핵을 가지고 있으며, 1개의 배아 당 평균적으로 8개 할구가 있습니다. *최소 2개 ~ 최대 10개의 할구가 있는 배아만 라벨링합니다. 할구는 서로 겹쳐져 있고, 잘 안보이는 부분은 추정하여 둥그랗게 그려야 합니다.
			fragmentation	할구가 분열하는 과정에서 생기는 세포로, 정상적인 세포보다는 크기가 작으면서 핵은 보이지 않는 미세한 거품형태의 세포조각을 말합니다. 배아 발달 등급을 판정할 때 파편화된 세포의 면적이 중요하게 작용하며 일반적으로 할구 사이에 눌러있어서 타원형으로 거품이나 포도알같이처럼 군집화되어있는 형상을 띠니다. 1개의 배아 내 없거나 / 여러 개의 영역이 존재할 수 있습니다.
	Day5 (5일차)		*TE	Trophectoderm(영양외배엽)의 준말로, 포배(blastocyst)의 바깥 부분에 존재하며 태반으로 발달하게 될 영역을 뜻합니다. inner안쪽에 ICM을 둘러싸고 있는 형태의 배아의 벽에 위치한 영양막으로 반원 모양의 띠(가랜드)처럼 보이며 타원형 세포가 도넛형태를 띠는 형상을 하고 있는 것이 특징입니다.
			ICM	Inner Cell Mass의 준말로, 세포덩어리이며 태아로 발달하게 될 영역을 뜻합니다. 일반적으로 TE와 붙어있는 세포 덩어리 형태로 모양이 불규칙한게 특징입니다. 하나의 배아에는 하나의 ICM만 존재합니다.

그림13| 데이터 가공 기준

● 가공(라벨링) 조직(슈퍼브에이아이)

- 슈퍼브에이아이는 인공지능 업계의 고질적인 난제인 데이터 문제(데이터 구축, 관리, 분석)를 해결하고자 설립되었습니다.
- 현재 B2B SaaS 머신러닝 데이터 플랫폼 스위트(Suite)를 서비스하고 있으며 스위트를 활용 한 데이터 구축사업과 데이터 품질 관리 사업 등을 수행 중입니다.
- 2021년 현재 기준, 스위트에는 미국 특허 등록 5건과 출원 4건 등의 성과를 거둔 세계 최고 수준의 데이터 라벨링 자동화 기술(오토라벨링, 커스텀 오토라벨링)이 탑재되어 있습니다.
- 머신러닝 개발과 데이터 운영을 통합하여 개발 효율성과 생산성을 극대화하기 위한 데이터 오픈스(DataOps), ML오픈스(MLOps) 선두주자로 한국 시장과 미국 시장을 공략하고 있습니다.

● 가공(라벨링) 도구

- 스위트(Suite)는 슈퍼브에이아이가 자체 개발한 플랫폼으로 AI 기반의 가공/검수, 작업자/검수자 기반의 가공/검수 시스템이 구성되어 있습니다.
- 주요기능
 - 데이터 통합/관리/분석 기능
 - 스위트 AI 기반 자동 라벨링
 - 데이터 분석 및 사용자 통계분석
 - 데이터 가공




그림14| 데이터 가공 도구

● 검사 절차

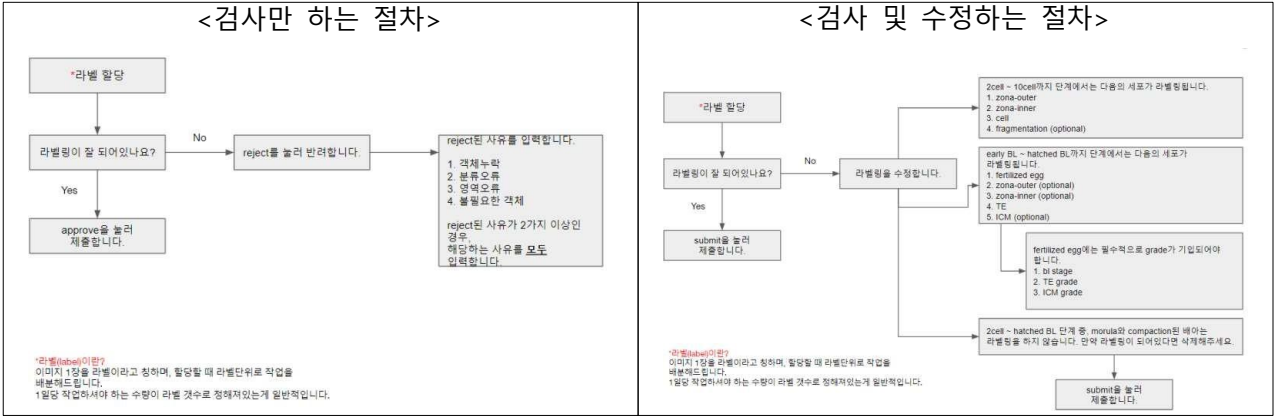


그림15| 데이터 검사 절차

● 검사 기준

- 검수자(작업자)는 데이터 가공 도구를 이용하여 작업자(라벨러)의 작업물을 보며 도구의 'issue'에 검수 내용을 기록합니다.
- 가공 데이터에 대해 객체누락, 분류오류, 영역오류, 불필요한 객체 등 총 4가지 오류 유형에 대해 의견 및 가공 제외 사유 등을 기술합니다.
- 검수자가 검수에 대한 의견을 기록하면, 라벨러는 검수의견을 보고 재작업을 수행. 검수자는 재검수를 거쳐 approve 또는 reject 처리합니다. (reject 처리 시, 라벨러 재작업 후 재검수 시행)




그림16| 데이터 검사 예시

● 검사 조직

- 다양한 유형의 배아 데이터 가이드라인을 기준으로 검수기준을 수립하고 3단계 검수를 시행합니다.
 - 1단계 : 일반인 작업자들의 라벨링 영역 전수 검수
 - 2단계 : 전문의 작업자들의 배아 발달단계, 라벨링 영역, 등급 등 전수 검수
 - 3단계 : 10년 이상 된 배아 전문가들의 교차 부분 검수(20% 수행)
- 라벨러 및 검사자에 대한 라벨태그를 부여함으로써 책임감을 부여하고, 특정 작업자의 작업 패턴을 파악하여 개인별 가이드라인을 제시합니다.
- 검사 도구에 reject 사유 기술 및 위치 지정을 통하여 작업자와 검사자 간 소통을 진행합니다.
- 전문의 의료 지식을 피드백하여 가이드라인 및 가공 프로세스에 반영합니다.

● 기타 품질관리 활동

- AI 외부 전문가 활용 : AI 전문가 활용을 통한, 데이터 관련 자문 및 AI 모델 검증 자문
- 외부 의료 전문가 활용(TTA) : 라벨링 데이터에 대해서 외부 전문가에 의한 재검증 과정 실시
- 품질담당자 : 임상-이미지 데이터 매칭과 라벨링 데이터 시각화로 데이터 품질 확인