
소아청소년 피부질환 이미지 데이터

Image dataset for pediatric and adolescent
dermatologic disease



건양대학교병원

**해당 자료는 AI-Hub에서 제공된 것으로,
저작권은 AI-Hub에 있으며,
원본 자료는 AI-Hub 웹사이트에서 확인하실 수 있습니다.**

<https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=data&dataSetSn=508>

ABOUT THIS REPORT

개요

서울대학교병원을 포함한 10개 병원이 참여하여 40가지 피부질환 데이터를 수집하고, 피부질환 진단을 위한 인공지능(AI) 알고리즘을 개발하는 것을 목적으로 합니다. 후향적 데이터와 전향적 데이터를 모두 수집하며, 각 병원에서 임상 자료를 정제하고 교차 검증한 후 개인 식별 정보를 제거하여 데이터베이스(DB)를 구축합니다. 구축된 데이터는 NIA 안심존을 통해 공개되며, AI 알고리즘은 웹 버전으로 제공됩니다.

데이터셋 목적

소아청소년 피부질환 이미지 데이터는 소아청소년 피부질환을 감별하고, 아토피피부염의 중증도를 판정하는 인공지능 알고리즘을 개발하는 데 목적이 있습니다. 40가지 대표적인 피부질환에 대한 58,186장의 사진 데이터가 포함되어 있으며, 이를 통해 의료 자원의 부족을 보완하고, 딥러닝 기술을 활용하여 피부질환 진단 AI 모델의 성능을 향상시키는 데 활용됩니다.

데이터 구축 과정

각 병원에서 수집한 임상 자료를 바탕으로 전향적, 후향적 데이터를 구분하여 진행됩니다. 전향적 데이터는 자원자로부터 동의서를 받아 수집되며, 후향적 데이터는 기존 병원의 데이터를 비식별화하여 사용합니다. 수집된 데이터는 레이블링 및 교차 검증 과정을 거치며, SQI소프트에서 학습용 및 검증용 DB를 구축합니다. 또한, 데이터는 NIA 안심존을 통해 연구자들에게 제공됩니다.

데이터 검수

각 병원에서 교차 검증을 통해 진행되며, 최소 두 명 이상의 피부과 의사가 라벨링된 정보를 검토합니다. 검수가 완료된 데이터는 개인 식별 가능성을 최소화하기 위해 비식별화 과정을 거치며, 얼굴 사진의 경우 눈 주위를 마스크하고, 사진과 임상 정보 간의 일련번호를 다르게 부여해 매칭 가능성을 낮춥니다. 검수 완료된 데이터는 학습용 DB에 저장되어 AI 모델 개발에 사용됩니다.

문의처

데이터에 대한 문의 사항은 다음 연락처로 연락주시기 바랍니다.

- 담당자명: 나정임(서울대학교 산학협력단)
- 전화 : 031-787-73414
- E-mail : jina1@snu.ac.kr
- 홈페이지 : www.aihub.or.kr

● 데이터 포맷

- 데이터는 피부 영상(JPG, JPEG, PNG 파일 형식)과 임상 정보(JSON 파일)로 구성됩니다.
- 아토피피부염의 경우, 병변 세그멘테이션 정보와 중증도 평가 정보가 JSON 파일에 추가됩니다.
- 피부 영상은 원본 이미지에서 병변 부분만 바운딩 박스를 사용해 크롭한 후, 해당 질환명 등 임상 정보를 라벨링하여 저장합니다.




그림1 | 제공되는 데이터 정보 (크롭 이미지 및 임상 정보)

● 어노테이션 포맷

- 데이터는 전향적 데이터와 후향적 데이터로 구분됩니다. 전향적 데이터는 동의서를 받고 촬영한 전체 사진을 공개할 목적으로 사용되며, 후향적 데이터는 기존 병원의 임상 사진을 비식별화하여 사용하는 경우를 말합니다.
- 전향적 데이터에는 임상 정보와 함께 촬영 정보가 포함되며, 후향적 데이터에는 임상 정보만 포함됩니다.
- 아토피피부염, 건선, 정상 피부의 경우, 피부와 배경, 정상 피부와 병변 피부를 구분하는 세그멘테이션 좌표 정보가 추가됩니다.

표1| 메타데이터(JSON) 항목

No	속성명	항목 설명	타입	필수 여부	작성예시
annotations (어노테이션)					
1	identifier	식별자	string	필수	
2	data_type	데이터 유형	String	필수	전향적/후향적
clinical_info (임상정보)					
3	gender	성별	String	필수	남/여
4	age	나이	integer	필수	세
5	onset	발병시기	String	필수	선천성/ 수 시간 전/ 수 일 전 /수 개월 전 /수 년 전 / 반복
6	distribution	병변분포	String	필수	단일 병변/부분 침범/넓은 침범
7	bodypart	신체부위	String	필수	
8	symptom	증상	String	필수	가려움/통증/무증상
9	diagnosis	피부질환	String	필수	[표3] 피부질환 참조
10	diagnosis_methods	진단기준	String	필수	병리진단 /임상진단 (치료반응확인) /임상진단 (자연경과확인)
11	iga_grade	중증도 단계	String	선택	0.Clear 1.Almost Clear 2.Mild 3.Moderate 4.Severe

12	erythema	홍반	String	선택	0 None 1 Mild 2 Moderate 3 Severe
13	papulation	구진	String	선택	0 None 1 Mild 2 Moderate 3 Severe
14	excoriation	줄까짐	String	선택	0 None 1 Mild 2 Moderate 3 Severe
15	lichenification	태선화	String	선택	0 None 1 Mild 2 Moderate 3 Severe
photograph (촬영 및 원본이미지 정보)					
16	camera	카메라구분	String	필수	DSLR/스마트폰/더모스코피
17	distance	거리구분	String	선택	원거리/근거리
18	direction	촬영방향	String	선택	
19	file_path	원본파일경로	String	필수	
20	width	원본 이미지 가로크기	number	필수	
21	height	원본 이미지 세로크기	Number	필수	
bbox (크롭이미지 정보)					
22	xpos	원본파일내 X좌표	Number	필수	
23	ypos	원본파일내 Y좌표	Number	필수	
24	file_path	크롭파일 경로	String	필수	
25	width	크롭 이미지 가로크기	Number	필수	
26	height	크롭 이미지 세로크기	Number	필수	
bbox.segmentations(세그멘테이션)					
27	x	x 좌표	Number	선택	
28	y	y 좌표	Number	선택	
29	skin_area	피부영역 이미지 경로	String	선택	피부/배경 분리
30	lesion_area	병변영역 이미지 경로	string	선택	병변/배경 분리

● 데이터 구성

- 데이터셋 폴더 및 파일 구조
 - 1차 경로는 전향적/후향적 데이터 구분에 따라 폴더명이 구성됩니다.
 - 2차 경로는 진단명에 따라 폴더명을 구성합니다.
 - 3차 경로는 각 데이터 셋의 식별자로 폴더명이 구성됩니다.
 - 후향적 사진의 경우, 원본 사진은 제공되지 않습니다. 또한, "아토피피부염"의 "crop" 폴더에는 크롭 이미지뿐만 아니라 피부/배경 분리 이미지와 피부/병변 분리 이미지 파일이 일부 저장됩니다.

표2| 데이터 파일 구성

ROOT 폴더	1차 경로	2차 경로	3차 경로	4차 경로	파일속성
D65	후향적	아토피피부염	{identifier}	crop	jpg/png
				metadata	json
		두드러기	{identifier}	crop	jpg/png
				metadata	json
		여드름	{identifier}	crop	jpg/png
				metadata	json
		멜라닌세포모반	{identifier}	crop	jpg/png
				metadata	json
		...			
	전향적	정상	{identifier}	org	jpg/png
				crop	jpg/png
				metadata	json

표3| 피부질환 종류

구분	진단명
염증성 피부질환 및 감별진단 7 가지	아토피피부염, 동전 습진, 건선, 두드러기, 곤충물림, 양진,여드름
선천성 피부질환 및 감별진단 11 가지	멜라닌세포모반, 몽고반점 및 이소성몽고반점, 밀크커피색반점, 베커 모반, 선천성 멜라닌세포모반, 연어반, 영아혈관종, 오타 모반, 표피모반, 피지선 모반, 포도주색 모반
감염성 피부질환 7가지	농가진, 단순포진, 물사마귀, 백선증, 사마귀, 수두, 어루러기
기타 15 가지	내향성 손발톱, 흑색선조, 손발톱이상증, 손발톱백선, 원형탈모, 백반증, 탈 색모반, 비만세포종, 선상태선, 소아황색육아종, 켈로이드, 태선모양 잔비 늘증, 피부낭종, 화농 육아종, 흉터
총 40 가지 진단	




그림2| 전향적 데이터 구조




그림3| 후향적 데이터 구조

● 데이터 예시

● 피부영상 데이터

- 피부영상 데이터는 JPG, JPEG, PNG 파일 형식으로 제공 됩니다.



그림4 피부영상 데이터 예시(전향적, 후향적)

● 메타데이터 구조

- 메타데이터는 JSON 타입으로 제공합니다.




그림5| 메타데이터(JSON) 예시

● 데이터 구축 규모

- 데이터 구축 규모
 - 최종 학습용 데이터 개수 58,186건 (임상사진 및 임상정보)
 - : 아토피피부염 10,166건
 - : 기타 39가지 질환 41,140건
 - : 정상 6,880건

표4| 데이터 통계

구분	제출 데이터(장)	제출데이터(비교)
아토피피부염	10,166	전향적데이터 3,054장 후향적데이터 7,112장 거의 없음: 2,087장/ 경증 3,613장/ 중등도: 2,792 장/ 중증: 1,674 장
기타 질환 (39종) (여드름/감염/선천성 피부질환 포함)	41,140	
정상	6,880	전향적데이터 5,414장 후향적데이터 1,466장
총 40가지 진단	58,186 영유아: 25,353장 (43.57%) 소아: 17,628장 (30.30%) 청소년: 15,205장(26.13%)	전향적데이터 8,468장 후향적데이터 49,718장 (환자 수 14,490 명)

● 원시데이터 특성

● 대상 분류

- 다음과 같은 수집 절차 및 촬영 장비를 이용하여 피부질환 임상자료를 수집했습니다.

데이터구분		수집처	데이터수집 장비	데이터형식	전향적 데이터	후향적 데이터
피부질환	아토피피부염	병원	DSLR	이미지 : JPG, JPEG, PNG	O	O
	기타질환	병원	DSLR, 더모스코피*		X	O
정상		병원	DSLR	임상정보 : EXCEL, CSV	O	O
		온라인	스마트폰		O	X

● 제약 조건

- 일부 제약 있습니다: 실내 사진 촬영

● 속성

- 사진 이미지:

- JPG, JPEG 또는 PNG 포맷의 파일. 원본 이미지의 경우 최소 1500만 화소, 되도록 2000만 화소 이상 권고합니다.
- 스마트폰 촬영의 경우, 후면카메라로 촬영을 진행하고, 가급적이면 1200만 화소 이상을 권고합니다.

- 임상정보 (메타데이터):

- EXCEL 또는 CSV 포맷의 파일

● 기타 정보

● 포괄성

- 지역별 다양성: 전국 각지에서 환자가 내원하는 병원을 대상으로 데이터가 수집됩니다.
- 빅4 병원: 서울대병원, 세브란스병원
- 서울권: 강남세브란스병원, 서울특별시보라매병원, 상계백병원
- 경기권: 분당서울대병원, 용인세브란스병원
- 영남권: 부산대병원, 양산부산대병원
- 호남권: 전남대병원
- 병원 규모의 다양성:
 - 빅4 병원: 서울대병원, 세브란스병원
 - 상급종합병원: 분당서울대병원, 강남세브란스병원, 부산대병원, 양산부산대병원, 전남대병원
 - 종합병원: 서울특별시보라매병원, 용인세브란스병원, 상계백병원

● 독립성

- 데이터는 보건의료 데이터 활용 가이드라인 및 개정된 데이터 3법을 준수하여 수집됩니다.
- 전향적 데이터: 병원 IRB 절차를 거친 후, 관련 동의서를 획득하여 데이터를 수집합니다. 자원자에게 본 사업을 설명하고, CC0 라이선스에 해당하는 동의서를 받습니다. 청소년 자원자의 경우 보호자와 자원자의 동의를 모두 받고, 미성년자는 보호자의 동의를 받습니다.
- 전향적 데이터에서 얼굴 사진: 눈 주위를 마스킹하여 개인 식별 가능성을 줄입니다. 또한 얼굴 사진과 기타 신체 사진에 서로 다른 일련번호를 부여해 직접적인 매칭 가능성을 낮춥니다.
- 후향적 데이터: 병원이 보유한 데이터를 보건복지부 가이드라인에 따라 개인 식별이 불가능한 크롭된 이미지로 가공하여 외부로 반출합니다.

● 유의사항

- 피부 병변 사진은 가명 데이터로 처리되지만, 다른 데이터와 결합할 경우 개인 식별 가능성이 존재할 수 있습니다. 따라서 사전에 허가된 사용자만 접근할 수 있도록 하며, 외부로의 데이터 반출을 차단합니다.
- 특히 눈을 가린 얼굴 사진의 경우, 개인 식별 가능성이 높아 더욱 주의가 필요합니다.

● 데이터 구축

● 데이터 구축 개요

- 본 사업은 서울대학교병원을 포함한 10개 병원에서 40가지 피부질환 데이터를 수집하며, 후향적 데이터와 전향적 데이터로 나뉩니다. 각 병원에서 데이터를 레이블링하고 개인식별 정보를 제거한 후, SQI소프트가 이를 수집하여 학습용 및 검증용 데이터베이스를 구축하고, 피부질환 진단 AI 알고리즘을 개발합니다. 구축된 데이터셋은 NIA 안심존을 통해 공개되며, AI 모델은 웹 버전으로 제공됩니다.




그림6 | 데이터 구축 flow

● 데이터 구축 유의사항

- 피부 사진은 개인 식별 가능성이 높으며, 특히 정면 얼굴 사진은 민감정보에 해당합니다.
- 자원자를 통해 수집한 데이터는 동의서를 받은 후 진행되며, 얼굴 사진은 눈 주위를 마스킹하여 식별 가능성을 낮춥니다.
- 얼굴 사진과 기타 신체 사진에는 서로 다른 일련번호를 부여해 직접적인 매칭 가능성을 줄입니다.
- 병원 데이터를 활용할 때는 보건복지부 가이드라인에 따라 개인 식별이 불가능한 크롭된 이미지만 외부로 반출합니다.
- 데이터는 민감 정보를 포함하므로 활용 시 개별 병원의 IRB 승인이 필요하며, 불법적인 데이터 반출은 엄격히 금지됩니다.

● 획득 및 정제

● 획득 및 정제 기준

- 임상정보 등록: 사진장부 리스트(엑셀 또는 CSV 파일)를 작성하여 일괄 등록한 후, 저작도구의 기능을 활용해 사진과 매핑된 메타정보를 생성합니다.
- 데이터 입력: 사진장부 리스트 작성 시 저작도구에서 제공하는 템플릿을 사용하고, 진단명은 표준화된 명칭으로 작성합니다. 예를 들어, "건선"의 경우 병원에서 다양한 진단명을 사용했더라도, 저작도구에서 자동으로 표준화된 진단명으로 라벨링됩니다.
- 메타데이터 수정: 진단명이 잘못 입력되어 자동 매핑되지 않은 경우, 저작도구를 이용해 수정합니다.
- Bounding Box 크롭: 매핑된 사진을 확인하고, 해당 병변을 Bounding Box 형태로 크롭하여 라벨링합니다. 크롭 시 해상도 최소 기준을 확인합니다.
- 세그멘테이션 추가: 아토피피부염의 경우, B-spline curve를 활용한 세그멘테이션을 추가하고, 학습용 데이터 생성 시 좌표 정보와 마스킹 이미지를 생성합니다.
- 데이터 편향성 확인: 저작도구의 통계 데이터를 통해 진단별, 나이별, 성별 등의 데이터가 편향되지 않도록 확인합니다.

● 부적합 데이터 선별

- 의료정보시스템에서 식별자(key)를 통해 데이터 확인이 불가능한 경우 제외합니다.
- 전문 학회에서 발간한 진료지침 또는 주요 임상연구에서 정의한 기준에 맞지 않는 데이터는 제외됩니다.

● 개인정보 비식별화

- 각 의료기관의 의료정보시스템은 데이터 추출 시 익명화 프로세스를 적용합니다.
- 추가로 비식별화가 필요한 경우 참여기관이 보유한 정제 도구를 사용합니다.
- 환자의 식별자(patient id)는 일련번호로 대체되며, 주요 인적사항인 주소는 삭제하고 생일은 연·월 정보만 남기고 삭제합니다.