
의료 분야 음성 데이터

Medical voice data



건양대학교병원

**해당 자료는 AI-Hub에서 제공된 것으로,
저작권은 AI-Hub에 있으며,
원본 자료는 AI-Hub 웹사이트에서 확인하실 수 있습니다.**

[https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=2
&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORDER001&srchPagePer=60&srchDataRealmCode=REALM006&aihubDataSe=data&dataSetSn=566](https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=2&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORDER001&srchPagePer=60&srchDataRealmCode=REALM006&aihubDataSe=data&dataSetSn=566)

ABOUT THIS REPORT

개요

의료 분야 음성 데이터는 병원 진료·상담 및 119 응급센터/콜센터 등에서 발생하는 의료 상담 음성을 기반으로 구축된 인공지능 학습용 데이터입니다. 실데이터 수집과 함께 관련 메타데이터를 기록하여, 다양한 음성을 텍스트로 표현하고 의미 분석이 가능하도록 구성합니다. 데이터셋 설계 시 데이터 밸런스와 구축 규모를 핵심 고려사항으로 두고, 정제·라벨링·검수 과정에서 제외되는 수량을 감안해 목표치 이상의 원시 데이터를 확보하도록 계획합니다. 원천 데이터는 보편적 활용이 가능하도록 특정 장비나 처리 도구에 종속되지 않는 포맷 기준으로 구축되어 있습니다.

데이터셋 목적

수십만 건 규모의 진료 및 의료 상담 음성 데이터를 안정적으로 확보하여, 신뢰도 높은 의료 상담 초기 진료 지원 시스템 구축과 도입에 활용하는 것을 목적으로 합니다. 이를 통해 의료 분야의 스마트화, 비대면 응급의료 시스템 등 의료 관련 미래 사업에서 AI 기술 활용도를 높이는 데 기여할 수 있습니다. 또한 실데이터 기반의 음성-텍스트 변환과 의미 분석을 지원하여, 실제 서비스 환경에서 활용 가능한 데이터 기반을 마련합니다. 구축 과정에서 STT 엔진 모델링을 수행해 중간 결과물로 모델 성능을 확인하는 흐름을 포함하였습니다.

데이터 구축 과정

본 데이터 구축은 시나리오 설계, 데이터 수집, 데이터 라벨링, 데이터 검수 순으로 진행됩니다. 데이터 수집은 의료 현장 진료·상담 녹취와 119 응급 및 콜센터 전화 상담 녹취 등으로 구성되어 총 1,000시간 규모로 구축합니다. 수집 단계에서 음원(wav)과 전사 텍스트(txt), 메타데이터(json)를 함께 확보·정리하여 후속 라벨링 및 활용이 가능하도록 합니다. 대규모 데이터 구축 이후에는 공인 인증 기관의 품질 검증을 거쳐 구축 데이터 및 STT API 공개로 이어지는 절차를 따릅니다.

데이터 검수

대량 데이터를 고품질로 생성하기 위해, 단가가 낮지만 품질 관리가 어려운 클라우드소싱 방식의 한계를 보완할 수 있도록 검수 프로세스를 정립합니다. 구축 공정(획득·정제·라벨링)별로 공통 적용 가능한 검사 요구사항을 반영해 검사 항목을 정의하고, 단계별 검수를 수행합니다. 또한 Data4Edu 데이터 구축 관리시스템의 분석 도구를 활용하여 어절·키워드·화행·연관어 등을 분석하고 데이터의 성격과 속성을 점검합니다. 이 과정을 통해 데이터 품질을 체계적으로 관리하고 최종 제공 데이터의 신뢰성을 확보합니다.

문의처

데이터에 대한 문의 사항은 다음 연락처로 연락주시기 바랍니다.


- 담당자명: 박보희 (충북대학교 산학협력단)
- 전화 : 043-261-2846
- E-mail : pbhmail26@gmail.com
- 홈페이지 : www.aihub.or.kr

데이터 포맷

- 데이터셋 구성
 - 예시, 데이터 항목, 실제 데이터(JSON) 예시

예시

음성



텍스트

A:그래서 이제 지난번에 그/ 뭐 환자분이 그 때 입원하셨을 때 폐렴 뭐 이런걸로 입원하셨었잖아요
B:네네
A:그러다가 저희가 류마티스 관절 확인을 했던거고 염증 수치나 뭐 이런거는 많이 떨어졌네요 그래서 거의 정상으로 떨어졌습니다
B:네네
A:지금 통증은 없으세요 어때요 많이 좋아지셨죠 아프신 거 들하시죠
C:네네 한결 들하죠
A:한결 들하죠 그죠
C:예
A:예 근까 원래 옛날 부터 있으셨던 것 같은데
C:예
A:그동안 치료 안받으셔서 손목은 다 그 때 막 썸/ 뻐던 보호자분을 제가 잘 모르겠는데 입원하실 때 설명 드렸었던 것 같애요 어떻게 보호자분 되게 남자분도 오시고 여자분도
B:예에 바깥어요
A:아 예에 그래서 돌아가면서 오서가지구 그래서 발이나 무릎이 아 뭐 퇴행성 변화고 손이랑 인제 손목이랑 발이랑 다 변화가 퇴행성 변화는 이거 오래된거예요
B:예예예
A:류마티스 관절 오래되신 거예요
B:맞아요
C:오래됐지요 몇 십년 됐지
A:그래서 이게 잠잠하다가도 저희가

데이터 항목

- 환자 구성(인원수)
- 환자 번호
- 환자의 연령대
- 환자의 성별
- 환자 간 관계
- 대화 장소
- 진료과
- 수집 데이터 매체 유형
- 진료 주제
- 119 응급 상황
- 콜센터 상담
- 의학 전문 용어
- 화행
- 글자 크기
- 수집 날짜

JSON 형식

```
{
  "dataset": {
    "identifier": 0,
    "name": "01-IM-05-01-00171_001",
    "src_path": "/data/file/cubeManager/PROJECT001/59/txt20211104113512079559/01-IM-05-01-00171_001",
    "label_path": "/data/file/cubeManager/PROJECT001/59/txt20211104113512079559/01-IM-05-01-00171_001",
    "category": 2,
    "type": 0
  },
  "licenses": {
    "name": "Apache License 1.0",
    "url": "http://www.apache.org/licenses/LICENSE-1.0"
  },
  "info": {
    {
      "id": 41974,
      "filename": "01-IM-05-01-00171_001.txt",
      "title": "01-IM-05-01-00171_001",
      "mediatype": "",
      "medianame": "진료상담",
      "category": "진료상담",
      "date": "2021-11-04",
      "size": 475,
      "annotations": {
        "subject": "류마티스내과",
        "speaker_type": "3명",
        "size": 475,
        "word_size": 120,
        "text": "A:그래서 이제 지난번에 그/ 뭐 환자분이 그 때 입원하셨을 때 폐렴 뭐 이런걸로 입원하셨었잖아요\nB:네네\nA:그러다가 저희가 류마티스 관절 확인을 했던거고 염증 수치나 뭐 이런거는 많이 떨어졌네요 그래서 거의 정상으로 떨어졌습니다\nC: ... \nB:예예예\nA:류마티스 관절 오래되신 거예요\nB:맞아요\nC:오래됐지요 몇 십년 됐지\nA:그래서 이게 잠잠하다가도 저희가",
        "lines": [
          {
            "id": 1,
            "text": "A:그래서 이제 지난번에 그/ 뭐 환자분이 그 때 입원하셨을 때 폐렴 뭐 이런걸로 입원하셨었잖아요",
            "norm_text": "A:그래서 이제 지난번에 그/ 뭐 환자분이 그 때 입원하셨을 때 폐렴 뭐 이런걸로 입원하셨었잖아요",
            "speaker": {
              "id": "1번",
              "sex": "여성",
              "age": "중년"
            },
            "speechAct": "(기타) 질문하기",
            "morpheme": "A/SL+/SC+/그래서/MAJ+/이제/MAG+/지난번/NNG+에/JKB+그/IC+/SC+/뭐/IC+/환자/NNG+분/NNB+이/JKS+그때/NNG+당원/NNG+하/XSV+었/EP+음/E+TM+데/NNG+폐렴/NNG+뭐/IC+/이런/IMM+경로/NNB+것/JKB+당원/NNG+하/XSV+었/EP+음/E+결어미/EC"
          },
          {
            "id": 2,
            "text": "B:네네",
            "norm_text": "B:네네",
            "speaker": {
              "id": "2번",
              "sex": "여성",
              "age": "중년"
            },
            "speechAct": "(표현) 긍정 표현하기",
            "morpheme": "B/SL+/SC+/네/NP+네/XSN"
          },
          {
            "id": 18,
            "text": "A:그래서 이제 잠잠하다가도 저희가",
            "norm_text": "",
            "speaker": {
              "id": "1번",
              "sex": "여성",
              "age": "중년"
            },
            "speechAct": "(지시) 설명하기",
            "morpheme": "A/SL+/SC+/그래서/MAJ+/이제/NP+하/JKS+잠잠/XR+하/XSA+다/가/EC+도/JX+저희/NP+가/JKS"
          }
        ]
      }
    }
  }
}
```

그림1 데이터셋 구성

● 어노테이션 포맷

표1| 어노테이션 포맷

구분		항목명	타입	필수 여부	설명	범위	비고
1		dataset			데이터셋 라벨 정보		
	1-1	identifier	number	M	데이터셋 식별자		
	1-2	name	string	O	데이터셋 명		
	1-3	src_path	string	M	데이터셋 폴더 위치		
	1-4	label_path	string	M	데이터셋 레이블 폴더 위치		
	1-5	category	number	O	데이터셋 분류		
	1-6	type	number	O	데이터셋 타입		
2		licenses			라이선스 라벨 정보		
	2-1	name	string	M	라이선스명		
	2-2	url	string	M	문서 식별자		
3		info[]			원시 데이터 라벨 정보		
	3-1	id	number	M	원시 데이터 고유번호		
	3-2	filename	string	M	원시 데이터 파일명	작업파일명.확장자	파일명규칙
	3-3	title	string	O	원시 데이터 제목	작업 파일명	
	3-4	mediatype	string	O	매체유형		
	3-5	medianame	string	M	데이터 매체(수집)	진료실, 전화상담, 기타	
	3-6	category	string	M	원시 데이터 카테고리	진료상담	주제별
	3-7	date	string	M	수집일자	YYYY-MM-DD	
	3-8	size	number	M	원시 데이터 크기(글자수)		
	3-9	annotations[]			원천데이터별 라벨링정보		
	3-9-1	subject	string	M	진료 주제	내분비내과, 심장내과, 알레르기내과, 호흡기내과, 류마티스내과, 간담췌외과, 흉부외과, 재활의학과, 신경학적 응급, 심혈관계 응급, 중독 및 대사장애, 외과적 응급증상, 출혈, 기타, 예약, 변경, 일반 상담, 기타	

			3-9-2	speaker_type	string	M	화자 구성	1명, 2명, 3명, 4명, N명	
			3-9-3	size	number	M	크기(글자수)		
			3-9-4	word_size	number	M	크기(단어수)		
			3-9-5	lines[]			문장별 정보		
			3-9-5-1	id	number	M	문장 번호		
			3-9-5-2	text	string	M	문장 내용		
			3-9-5-3	norm_text	string	M	정제된 문장내용		
			3-9-5-4	speaker			화자 정보		
			3-9-5-4-1	id	number	O	화자 식별정보		
				sex	string	O	화자의 성별	남, 녀, 모름	
				age	string	O	화자의 연령대	소아, 청소년, 청년, 중년, 장년, 노령	
			3-9-5-5	speechAct	string	O	화행	단언 질문하기, 단언 주장하기, 단언 진술하기, 단언 반박하기, 지시 설명하기, 지시 충고/제안하 기, 지시 명령/요구 하기, 지시 부탁하 기, 언약 약속하기, 언약 위협하기, 언약 거절하기, 표현 인사하기, 표현 감사하기, 표현 사과하기, 표현 울음/슬퍼하 기, 표현 웃음/즐거 워하기, 표현 긍정 표현하기, 표현 부 정 표현하기, 기타 관습적 표현, 기타 미정의	
			3-9-5-6	morpheme	string	M	형태소 분석데이터		

```

{
  "dataset": { → 데이터셋 정보
    "identifier": 94962,
    "name": "03-EC-01-YY-13200_003", → 파일명
    "src_path": "/data/file/cubeManager/PROJECT001/66/txt20211117103838078753/03-EC-01-YY-13200_003/",
    "label_path": "/data/file/cubeManager/PROJECT001/66/txt20211117103838078753/03-EC-01-YY-13200_003/",
    "category": 2, → 카테고리 번호
    "type": 0 → 타입
  },
  "licenses": {
    "name": "Apache License 1.0", → 오픈 소스 라이선스
    "url": "http://www.apache.org/licenses/LICENSE-1.0" → 데이터셋 url
  },
  "info": [ → 데이터셋 정보
    {
      "id": 58184, → 음성데이터 번호
      "filename": "03-EC-01-YY-13200_003.txt", → 텍스트 파일명
      "title": "03-EC-01-YY-13200_003", → 파일명
      "mediatype": "",
      "medianame": "전화상담", → 수집 매체
      "category": "진료상담", → 진료 카테고리
      "date": "2021-11-17", → 데이터 정제 날짜
      "size": 34, → 글자 수(크기)
      "annotations": {
        "subject": "예약", → 주제
        "speaker_type": "2명", → 화자 수
        "size": 34, → 글자 수(크기)
        "word_size": 8, → 단어 수
        "text": "A:영상등록기에다 등록을 하고 진료과로 가십쇼\nB:네/ 네\nA:네", → 대화 내용
        "lines": [
          {
            "id": 1, → 화자 번호
            "text": "A:영상등록기에다 등록을 하고 진료과로 가십쇼", → 전사 텍스트
            "norm_text": "A:영상등록기에다 등록을 하고 진료과로 가십쇼", → 정제 텍스트
            "speaker": { → 화자 정보
              "id": "1번", → 화자 번호
              "sex": "여성", → 화자 성별
              "age": "중년" → 화자 연령
            },
            "speechAct": "(지시) 설명하기", → 화행
            "morpheme": "A/SL+:/SC+영상/NNG+등록기/NNG+에다/JKB+등록/NNG+을/JKO+하/VV+고/EC+진료/NNG+과로/NNG+가/JKS+십/NR+쇼/NNG" → 형태소 분석
          },
          {
            --
          },
        ]
      }
    }
  ]
}

```

그림2| 실제 JSON 형식 예시

● 데이터 구조

- 폴더 및 파일명 구조

	폴더 경로				파 일
명 칭	도메인	1차 분류	2차 분류	순 번	데이터셋 파일
예 시	01	IM	01	00001 . .	01-IM-01-00001.wav 01-IM-01-00001.json 01-IM-01-00001.txt
설 명	01: 진료	IM : 내과	01 : 내분비내과 02 : 심장내과 03: 알레르기 내과 04 : 호흡기내과 05 : 류마티스 내과	일련 번호	
		SU : 외과	01 : 간담췌외과 02 : 흉부외과		
		PE : 기타	01 : 재활의학과		
	02 : 119응급	EM : 119응급의학과	01 신경학적 응급 02 : 심혈관계 응급 03 : 중독 및 대사장애 04: 외과적 응급 05 : 출혈 06 : 기타		
	03 : 콜센터	EC : 콜센터 진료예약	01 : 예약 02 : 변경 03 : 일반상담 04 : 기타		

	데이터셋 구분	대분류	과별 세부 분류	파일 순번	시리즈번호	확장자
원천데이터	01	- IM	- 01	- 00001	_001	.wav
	01	- IM	- 01	- 00001	_001	.txt
라벨링데이터	01	- IM	- 01	- 00001	_001	.json

그림3| 폴더 구조 및 파일명 규칙

● 데이터 구축 규모

- 100시간의 진료 음성데이터와 900시간의 상담 텍스트 데이터로 총 1,000시간의 데이터로 구성됩니다.

표2| 데이터 구축 규모

데이터 도메인	수집 시간	파일개수(예상)	제공 방식
환자 진료 데이터	100시간	약 1,200개 (회당 약 1분 분량)	wav 음원 txt 전사파일 json 메타파일
119 응급센터 데이터	300시간	10만 문장	txt 전사파일 json 메타파일
콜센터 상담 데이터	600시간		
총 합계	1,000시간		

표3| 진료 음성 데이터 구축 규모


분류	주제	데이터구축량 (시간)
내과	내분비내과	100시간
	심장내과	
	알레르기내과	
	호흡기내과	
	류마티스내과	
외과	간담체외과	
	흉부외과	
기타	재활의학과	

표4| 상담 텍스트 데이터 구축 규모


분류	주제	데이터구축량 (시간)
119	신경학적 응급	900시간 (10만 문장)
	심혈관계 응급	
	중독 및 대사장애	
	외과적 응급증상	
	출혈	
콜센터	기타	
	예약	
	변경	
	일반상담	
	기타	

● 데이터 분포

성별




연령대




카테고리별

환자 진료 (100시간 2분 56초)



119 응급 (308시간 5분 2초)



콜센터 (600시간 7분 30초)




그림4| 범주별 데이터 분포

● 원시데이터 특성

● 대상 분류

- 실 녹취된 음성 데이터에 대한 검토 결과, 개인 데이터 유출 문제가 발생할 것으로 판단
- 실데이터 녹취록 클라우드 소싱 전사 및 음성 편집 작업 진행(개인정보 비식별화 마크업 및 무음처리)

● 제약 조건

- 당초 목표였던 10개 진료과 중 진료과 및 질환의 특성상 음성 녹음이 어려운 응급의학과와 비뇨의학과를 제외한 8개의 진료과를 대상으로 진료 음성 데이터 구축 목표량인 100시간 달성
- 각 음성 데이터 당 재생시간의 길이에 제한이 있음

● 속성

- 파일형식: wav, m4a
- 샘플레이트: 0~44.1khz

● 기타 정보

● 독립성

- 진료 음성 데이터 획득 과정에서 개인정보가 포함됨에 따라 점검표 작성 후 제출
- 연구대상자 동의서 및 설명문에 개인정보 활용 문항을 삽입하여 연구대상자에게 설명 및 동의를 얻어 사본 발급 진행
- 상담 텍스트 데이터 (119 응급 데이터, 콜센터 상담 데이터)는 IRB 심의를 통하여 동의 면제 승인을 받아 개인정보동의서 미작성
- 콜센터 상담데이터 반출과 관련하여 개인정보보호법으로 인해 외부 반출 시 충북대학교병원 측에서 개인정보 비식별화 처리 후 반출이 가능하며 클라우드워커 내원 후 비식별화 작업 후 데이터를 획득
- 연구대상자 동의서 및 설명문에 AI Hub에 데이터가 공개될 예정이라는 문장을 삽입하여 연구대상자에게 설명 및 동의 획득

● 유의사항

- 영문으로 된 의료전문용어는 표준표현과 발화표현을 구분하여 사전을 제작한다.
- 데이터 당 1분 내외 길이로 제한한다.
- 데이터셋으로 구성 시에 본 과제에서 제공하는 전사 규칙이 기반한 가이드에 따라 데이터를 가공한다.

● 데이터 구축

● 데이터 구축 절차



그림5 데이터 구축 절차 단계별 세부 내용

● 데이터 임무 정의

- 병원에서의 진료 예약시 증상에 따른 최적의 진료과를 지정하여 예약하게 함으로써 환자의 만족도 증진 및 진료의 효과성 재고
- 의료 관련 용어 등에 대한 인공지능 학습 과정에서 데이터 평가 모델 및 알고리즘 구축을 통해 의료인 수준의 의료 상담 음성 인식 모델 구축
- 충북대학교 병원의 진료 예약 등의 상담 음성 데이터를 전사 처리한 상담 텍스트 데이터 10문장 (900시간)과 의료진들의 진료 현장을 녹음한 진료 음성 데이터 100시간을 수집하고 이를 이용해 상담 텍스트 데이터와 진료 음성 데이터가 활용될 수 있도록 지원
 - 충청북도 소방본부는 충북대학교 병원의 진료 예약 상담 음성 데이터와 해당 증상에 대한 진료과 매칭 데이터를 인공지능 학습을 시킴으로써 소방본부 응급 의료 신고 전화에 의료 AI 챗봇을 활용할 수 있는 수요기관으로 참여
 - 충북대학교 병원의 진료 예약 등의 상담 음성 데이터는 실제 의료 현장에서 발생할 수 있는 데이터로 인공지능 데이터 학습용으로는 최적의 데이터를 제공

● 수집 및 정제

● 수집 절차



그림6 데이터 수집 절차

● 수집 목적

- 병원: 초기 진료 지원 AI활용 후 병원 상담자들의 정확한 진료과 예약 및 담당 의사들 대상 진료 예약 환자들에 대한 진료 정보 제공
- 소방본부 등 응급의료기관: 응급 의료 담당자들의 초기 처치를 위한 정보지원 후 환자의 증상에 최적화된 맞춤형 치료를 위한 의료 지도 및 병원 안내

● 수집 고려사항

표5 데이터 수집 시 고려사항

고려사항	설 명
서비스와 활용성	-원시 데이터 획득 후 정제, 라벨링, 검사 과정에서 검사 기준 미 충족으로 제외되는 데이터 수량을 고려하여 구축 목표치 이상의 데이터를 획득하도록 계획에 반영하며, 최소 1.5배 이상의 원시 데이터를 확보 -원시 데이터의 파일 형식은 특정 수집 장비 및 처리 도구에 종속 되지 않으며, 원시 데이터 처리, 학습 데이터 및 서비스 활용 등에서 보편적으로 데이터를 활용할 수 있도록 동일한 데이터 포맷을 기준으로 하여 구축
소 음	•데이터 품질 향상을 위해 실제 활용 환경을 고려한 환경 소음을 포함하여 실데이터 특성을 살림
데이터의 균형	•녹취되는 성별의 균형 •녹취인 나이의 다양성 •진료과 카테고리의 다양성


● 정제 기준

표6| 원천데이터 정제 기준

원천데이터 정제 기준	설 명
스크립트 적합성 여부	스크립트와 발화 내용의 적합성 여부
소음 여부	•현장 소음 포함 여부 •소음의 강도 •음성의 명확성
음원 파일의 적합성	•요구되는 음원 파일의 요구에 부합 여부 - WAV 또는 M4A, PCM(코덱), 0~44.1KHz, Mono 또는 스테레오

● 정제 절차

- 음성파일에서 텍스트를 추출하고, 음성을 분할 된 단위로 텍스트 추출
- 음성파일과 텍스트 파일 각각에 대한 저작도구를 활용한 레이블링 진행
- 음성파일 레이블링
 - 1) 작업 폴더내 음성 파일 리스트 확인
 - 2) 음성파일을 음성 인식 엔진(STT) 을 이용하여 자동 전사 처리
 - 3) 음성파일 편집
- 재생, 정지, 일시 멈춤, 다음 파일 재생, 구간 반복, 무음, 변조, 자르기
 - 4) 문장 단위 자동 전사 결과 표출, 전사 텍스트 편집, 문장 재생
 - 5) 전사 텍스트 전체 저장과 1분 내외 단위 전사 텍스트로 분할 저장
 - 6) 전사 텍스트 정제 화면으로 전환



그림기 음성파일 레이블링 과정

가공 및 검사

가공(라벨링) 절차



그림8 라벨링 작업 프로세스

- 대화셋 구축 전체 절차는 사전 정제 단계 → 저작도구를 활용한 시스템 구축 단계 → 외부 검수 단계 → 최종 리포트 제출을 위한 후처리 공정으로 이루어집니다.

표기 대화셋 구축 전체 절차

구 분	단 계	내 용	비 고
사전정제	정제	•의도 및 맥락 파악 해당 대화셋을 읽고 전체의 의도 및 맥락 파악 •도메인 및 카테고리 파악 도메인 및 카테고리를 정함 •개인정보 삭제 개인정보는 사전 정제 차원에서 제외 •비문 해석 STT 번역 과정에서 발생하는 비문에 대한 파악 및 해석	
저작도구 를 활용한 시스템 구 축 (대화셋 입력)	입력	•입력 문장내용, 문장타입, 의도입력 또는 선택, 개체, 용어사전, 지 식베이스	
	전수검수	•전수 검수 입력자의 대화셋을 전수 검수하며, 필요 시 반려	
	선별검수	•선별검수 전수검수 완료된 내용 중 10~20%를 선별하여 검수를 진행 하고, 필요시 반려 선별검수가 필요치 않은 내용은 선별 Pass 처리	
외부검수	-	•세부 내 검수 검수를 담당한 충북대, 남서울대 등 전문가에 의한 세부 내 검수 진행	필요시 수정
후처리 (최종리포트 제출)	-	•최종 구축 데이터 준비 최종 구축 데이터셋 준비 •최종 제출 데이터 가공 최종 제출을 위한 데이터 가공 시 필요한 후처리 작업 진행	필요시 수정

● 가공(라벨링) 기준

1.1. 개요 1.1.1. 발성된 내용을 소리 값에 최대한 가깝게 표기하며 작업자가 임의로 수정하지 않는다. 1.1.2. 전사 작업 결과물은 utf-8형식의 txt파일로 저장하며 txt파일명과 wav파일명은 반드시 일치해야한다. ex) 01-IM-05-01-00002.wav 를 듣고 전사한 파일명은 01-IM-05-01-00002.txt	1.1.3. 철자전사 : 표준어법에 맞게 표기한다. 이는 음성인식의 언어모델링 등을 주된 목적으로 한다. 1.1.4. 숫자, 외래어, 기호, 도량형 및 온도 단위는 발음 전사를 수행하되, 별도의 목록표를 생성하여 발음 전사별로 해당되는 표준 표기를 명시한다 1.1.5. 이중전사를 할 때, 이중전사의 범위를 표시하기 위해 괄호('(', ')')를 사용한다. 1.1.6. 이중전사, 잡음, 중복 발생 등을 나타내기 위한 특수 기호(meta symbol, 예: '/', '(', ')', '*', '+')는 원래의 목적으로만 표기되어야 한다. 특수기호가 실제 발생된 경우에는 발생된 형태를 반영하여 발음전사 한다. 분수 표기도 풀어서 표기한다. 1.1.7. 전사 과정에서 삽입되는 모든 기호('0, /'등)는 아스키코드만 사용하도록 한다. 1.1.8. 전사 문장 중에 마침표나 물음표, 느낌표 등 전사규칙에 포함되지 않는 기호는 사용하지 않는다. 1.1.9. 이중전사 할 때 '/'와 앞 뒤 괄호 사이에는 space를 두지 않는다. 1.1.10. 대화체 문장은 문장 자체가 이상하더라도 그대로 전사한다. 1.1.11. 띄어쓰기는 표준어법에 맞추어 하되 표준어법으로 명확히 결정할 수 없는 경우에는 띄운다. 1.2. 파일명 및 화자 설정 1.2.1. 파일명 설정 전사 텍스트 파일명과 오디오 음원의 파일명은 일치해야 하며, 각 분류 체계별로 다음과 같은 의미를 갖는다. 파일명은 환자진료, 119응급, 콜센터 총 3가지이다. 환자진료 데이터 : 01-IM-xxxx , 01-SU-xxxx , 01-PE-xxxx 로 시작 119응급 데이터 : 02-EM-xxxx 로 시작 콜센터 데이터 : 03-EC-xxxx 로 시작 1.2.2 화자설정 음원 중 처음 발성한 화자는 A:으로 표기하고 이후에 말하는 사람은 B:로 표시하며, A,B 알파벳과 콜론 : 기호 사이의 띄어쓰기는 없다. 화자가 추가되는 경우 C, D, E, ... 로 화자가 추가된다. ex) A:네 진료과는 처음 오신 건가요 B:작년에 왔었어요 A:오늘은 무엇을 도와드릴까요 1.3. 긴 발성 및 잡음 처리 1.3.1. 긴 발성의 전사 한 명의 말이 계속 이어지는 경우 문단 구분은 하지 않고 한 줄에 계속 전사한다. 화자가 바뀌는 경우만 문단이 구분이 다음 줄에서 시작한다. ex) A:고객님 예전 차트를 확인해보니 심근경색 진단을 받으셨더라고요 하지만 고객님의 문의하시는 내용은 심근경색과는 상관이 없는 내용이기 때문에 그 증상으로 진료예약을 원하시는 경우에는 다른 병원에서 의뢰서를 가져오셔야 해요 진료 의뢰서가 없는 경우에는 진료를 못보실 수 있어요 B:네 알겠습니다 1.3.2. 수화기 밖에서 들리는 소리는 전사하지 않고 무시한다. ex) 병원 직원과 구급대원 간 대화 중, 구급대원이 환자에게 말을 거는 경우 - 무시 ex) 동료 구급대원이 바이탈 정보를 크게 말해주는 경우 - 무시 ex) 병원 측 화자(전화 통화 하는 사람)과 의사(수화기 밖)가 대화를 나누는 경우 - 무시 1.4. 간투어 표기 1.4.1. 간투어는 발성자가 다음 발성을 준비하기 위해서 소요되는 시간을 벌기 위해서 발성하는 의미 없는 말을 의미한다. 간투어 뒤에 슬래쉬 / 를 붙여 표기한다. ex) 아/, 그/, 어/, 그/, 아/, 음/, 저/, 저기/, 예/, 으/, 응/, ... 등 ex) A:음/ 진료 받으신 지는 얼마나 되셨어요
---	--

그림9 | 가공(라벨링) 기준 (1)

A:아/ 예 작년부터 받으셨 으셨어요

1.2.5. 특수 기호

(마침표), ? (물음표), ' (따옴표), * (쌍따옴표), (원표) 전부 사용하지 않는다.

영어 알파벳 사용하지 않는다(※예외 : 숫자 이중전사 시 ml, cc, cm 등의 도량 단위를 나타낼 때는 사용)

영문으로 된 의학 전문 용어에는 단어 뒤에 특수문자 + 별 표시를 마킹한다.

ex) A: 환자분 바이탈* 좀 불러주세요
B: 현재 피버*는 정상이고 멘탈* 얼러트*하시구요
A: 코로나* 확진자는 아니시죠
B: 아스트라제네카* 맞으셨다고 해요

의학 용어 사전은 별도 사전데이터 제공함

ex) - 세츄레이션*, 새츄리*, 세츄*, 세투레이션*, ...
 - 코로나*, 코비드*, 코로나* (19)/(일 구), 코로나바이러스*, ...
 - 체크스트레인* 체크스트페인*, 체크스트팬*, 체크스페인*, ...
 - 류마티스*, 루마티스*, 류마티스* 관절염, 유마티스*, ...

음성 중 개인 식별정보인 전화번호, 이름, 주민번호, 주소, 이메일 등이 있는 경우는 반드시 시작과 끝의 해당부분에 #@와 *기호를 이용해 개인 정보를 비식별화 한다. 이름이 2개 이상 나오는 경우에는 #@이름1#, #@이름2#, #@이름3#, ... 으로 표기한다. 참고 : 비식별화 처리 라벨링)

이름은 #@이름#과 같이 비식별화 처리를 한다.

ex) [wav : 환자분 이름이 어떻게 되시죠 / 네 홍길동입니다 / 아 홍길동 네 확인했습니다]
A:환자분 성함을 불러주세요
B:네 #@이름1#입니다
A:아까 말씀하신 #@이름2#과의 관계는 어떻게 되시죠
B:네 저는 아들입니다
A:그럼 #@이름3# 교수님으로 예약도어드릴까요

전화번호는 #@전번#과 같이 비식별화 처리를 한다

단, 통신번호(010, 011, 016 등) 또는 지역번호(02, 031, 042, ... 등)는 전번 처리하지 않고, 숫자 이중전사하며, 병문 내선번호 또는 인터넷 검색 가능한 번호는 전번 처리하지 않고 숫자 이중전사 한다.

ex) [wav : 한자본 전화번호가 어떻게 되시나요 / 전화번호는 공일공 일일일일 삼삼삼삼입니다 아/ 내분비내과 전화번호 알려주세요 / 네 내분비내과가 공사이 누르시고 일이사에 사오욱칠입니다]
A:한자본 전화번호가 어떻게 되시나요
B:제 전화번호는 (010)/(공 일 공) #@전번#입니다 아/ 내분비내과 전화번호 알려주세요
A:네 내분비내과가 (042)/(공 사 이) 누르시고 (123)/(일 이 사)에 (4567)/(사 오 욱 칠)입니다

1.6.3. 생년월일, 주민번호, 환자 번호 등 비식별화

그림10이 가공(라벨링) 기준 (2)

생년월일, 주민번호, 환자 번호 등 개인 정보는 #@신원#으로 표기한다. 이때, 나이, 년생은 신원 처리하지 않고, 숫자 이중전사 한다.

ex) [wav : 생년월일 불러주세요 / 네 삼십이년생 시월 삼십일 이요 / 네 고객님의 환자 번호가 이삼이일오 시네요 / 네 이삼이일오 / 성함이 홍길동 님이요 / 네 맞습니다]

A:생년월일 불러주세요

B:네 (32)/(삼십 이) 년생 #@신원# 이요

A:네 고객님의 환자 번호가 #@신원# 시네요

B:네 #@신원# 맞습니다

1.6.4. 주소 비식별화

개인의 주소는 #@주소# 로 표기한다.

- 도 > 시 > 구 > 동(읍/면리) 이후의 상세 주소부터 #@주소# 처리

- 도로명(~길, ~로, ~로서 등) 주소는 상세 주소이므로 #@주소# 처리

ex) [wav : 환자분 주소 불러주세요 / 네 충남 청주시 / 네 청주시 / 서원구 / 네 서원구요 / 네 서원구 1순환로 776 이에요]

A:환자분 주소 불러 주세요

B:네 충남 청주시

A:네 청주시

B:서원구

A:네 서원구요

B:네 서원구 #@주소# 이에요

1.6.5. 소속 비식별화

개인의 직장/학교 이름은 #@소속# 으로 표기하며, 병원 및 구급대 등 소속은 그대로 표기한다.

ex) A:충북대학교 응급실입니다

B:네 세종 구급대입니다 성모병원 자리가 없어서 연락드렸습니다

A:어떤 환자인가요

B:학교 앞에서요 #@소속# 학생이라는데 수업중 갑자기 의식을 잃었다고합니다

1.6.6. 비식별화 처리가 애매한 경우

이름, 전번, 식별번호, 신원, 소속 등을 말해주는 과정에서 의사소통에 오류가 있는 경우, 오류 사항은 식별화 #@마크업# 작업 하지 않고, 들리는대로 모두 전사한다. 정확한 #@이름#, #@전번#, #@신원#, #@주소#, #@소속#만 식별화 마크업 처리한다.

ex) [wav : 성함이랑 생년월일 알려주세요 / 네 홍길동여구요 / 뭐라고요 손동길이요 / 아니 홍시할 때 홍길거리 할 때길 / 네 홍 길 / 동네 할 때 동이요 / 아하 홍길동이라고요 / 네 맞아요 / 그럼 생년월일은요 / 95년 8월 7일이요 / 7월 18일이라고요 / 아니요 8월 7일이요 / 아 네 8월 7일 / 네 네 맞습니다]

A:성함이랑 생년월일 알려주세요

B:네 #@이름# 이구요

A:뭐라구요 손동길이요

B:아니 #@이름#

A:네 #@이름#

B:#@이름#이요

A:아하/ #@이름#이라고요

B:네 맞아요

A:그럼 생년월일은요

B:(95)/(구십 오)년 #@신원# 이요

A:(7)/(칠)월 (18)/(십 팔)일이라고요

	B:아니요 #@신원# 이요 A:아/ 네 #@신원# B:네네 맞습니다
	36.6. 노이즈, 말걸침 등으로 청음이 어려운 경우 안 들리거나, 노이즈가 있거나, 동시에 발생해서 말이 겹치는 등 부분적으로 전사가 어려운 경우는 #@모름# 으로 표기한다
ex)	A:방문날짜를 언제로 할까요 B:잠깐만요 다음주 #@모름#면 좋을것 같아요 A:죄송하지만 잘 안들렸습니다 다시 말씀해주세요
	1.7. 이중전사
	1.7.1. 시간, 날짜 이중전사 개인정보에 해당하지 않는 시간, 날짜, 기호 등이 나오는 경우는 (숫자표기)/(한글표기)와 같이 이중으로 표기하며 /와 앞 뒤 괄호 사이에는 간격 space를 두지 않는다.
ex)	[wav : 환자분 사월 이십구일 열한시 반으로 예약해드렸습니다 / 네네 감사합니다] A:환자분 (4)/(사)월 (29)/(이십 구)일 (11)/(열 한)시 반으로 예약해 드렸습니다 B:네네 감사합니다
	1.7.2. 도량, 단위 이중전사
	- (숫자표기)에는 특수문자 ,(마침표), -(대쉬), %(퍼센트) 및 도량 단위(cc, ml, cm 등)가 포함된다 - (문자표기)에는 들리는 한글로만 작성한다. 단위 별로, 숫자 자리수대로 띄어쓰기를 해야 한다.
ex)	[wav : 이런 증상 언제부터 있었어요 / 한 사오년 전부터요] A:이런 증상 언제부터 있었어요 B:한 (4-5)/(사 오)년 전부터요
ex)	[wav : 환자 바이탈 불러주세요 / 네 지금 비피는 백이십삼에 칠십팔 나오시고 하트레이트 칠십육회 확인 되시고 / 환자 체온 몇 도예요 / 현재 피버 육도 팔이요 / 아 삼십칠 점 팔도 라구요 / 네] A:환자 바이탈* 불러주세요 B:지금 비피*는 (123)/(백 이십 삼)에 (78)/(칠십 팔) 나오시고 하트레이트* (76)/(칠십 육) 회 세추레이션* (95%)/(구십 오 퍼) 체온은 (36.6도)/(삼십 육 점 육 도) 확인 되시고 A:환자 체온 몇 도라구요 B:현재 피버* (7도8)/(칠 도 팔)이요 A:아/ (37.8도)/(삼십 칠 점 팔 도) 라구요 B:네
	1.7.3. 숫자의 한글표기
	- (1)/(한) 달, (2)/(두) 달, (3)/(세) 달, ... - (1)/(일) 주, (2)/(이) 주, (3)/(삼) 주, ... ※ 단, "일주일" 은 이중전사 하지 않는다. - (1)/(한) 번, (2)/(두) 번, (3)/(세) 번, ... - (1)/(한) 분, (2)/(두) 분, (3)/(세) 분, ... - (1)/(한) 가지, (2)/(두) 가지, (3)/(세) 가지, ... - (1)/(하나) 씩, (2)/(둘) 씩, (3)/(셋) 씩, ... - (1)/(한) 개씩, (2)/(두) 개씩, (3)/(세) 개씩, ...
	※ 첫째, 둘째, 셋째, 넷째, ... : 이중전사 하지 않는다.
	※ 첫번째, 두번째, 세번째, ... : 이중전사 하지 않는다.
	※ 하루, 이틀, 사흘, 나흘, ... : 이중전사 하지 않는다.
	*. 특수기호로 또는 영문으로 된 단위는 이중전사한다. (숫자전사) 안에 특수기호/영문 단위를 표기한다. - % : (132%)/(백 삼십 이 퍼센트), (132%)/(백 삼십 이 퍼), (132%)/(백 삼십 이 프로) - cm : (123cm)/(백 이십 삼 센치), (123cm)/(백 이십 삼 씨엠), (123cm)/(백 이십 삼 센티미터), (123cm)/(백 이십 삼 씨메다) - ml : (23mm)/(이십 삼 미리), (23mm)/(이십 삼 미리리터), (23mm)/(이십 삼 밀리리터)
	※ 화자가 "미리" 라고만 말하여 ml인지 mm인지 파악이 어려운 경우, 문맥을 파악하여 임의로 작성한다.
	※ 숫자 이중전사 내 cc, ml, cm 등의 도량 단위에는 * 표시하지 않는다.

그림12| 가공(라벨링) 기준 (4)

- 라벨링 작업 방식

- 목적 대화 데이터의 경우, 상황에 대한 분석과 판단이 필요하므로, 사람이 직접 원천데이터의 내용을 파악하고 라벨링 하는 방식으로 진행됩니다.
- 정확한 라벨링 확인을 위하여 2차 검증 프로세스를 마련하여 오류를 최소화 합니다.


```

{ "dataset": { → 데이터셋 정보
  "identifier": 94962,
  "name": "03-EC-01-YY-13200_003", → 파일명
  "src_path": "/data/file/cubeManager/PROJECT001/66/txt20211117103838078753/03-EC-01-YY-13200_003/",
  "label_path": "/data/file/cubeManager/PROJECT001/66/txt20211117103838078753/03-EC-01-YY-13200_003/",
  "category": 2, → 카테고리 번호
  "type": 0 → 타입
},
"licenses": {
  "name": "Apache License 1.0", → 오픈 소스 라이선스
  "url": "http://www.apache.org/licenses/LICENSE-1.0" → 데이터셋 url
},
"info": [ → 데이터셋 정보
  {
    "id": 58184, → 음성데이터 번호
    "filename": "03-EC-01-YY-13200_003.txt", → 텍스트 파일명
    "title": "03-EC-01-YY-13200_003", → 파일명
    "mediatype": "",
    "medianame": "전화상담", → 수집 매체
    "category": "진료상담", → 진료 카테고리
    "date": "2021-11-17", → 데이터 정제 날짜
    "size": 34, → 글자 수(크기)
    "annotations": {
      "subject": "예약", → 주제
      "speaker_type": "2명", → 화자 수
      "size": 34, → 글자 수(크기)
      "word_size": 8, → 단어 수
      "text": "A:영상등록기예다 등록을 하고 진료과로 가심쇼\nB:네/ 네\nA:네", → 대화 내용
      "lines": [
        {
          "id": 1, → 화자 번호
          "text": "A:영상등록기예다 등록을 하고 진료과로 가심쇼", → 전사 텍스트
          "norm_text": "A:영상등록기예다 등록을 하고 진료과로 가심쇼", → 정제 텍스트
          "speaker": { → 화자 정보
            "id": "1번", → 화자 번호
            "sex": "여성", → 화자 성별
            "age": "중년" → 화자 연령
          },
          "speechAct": "(지시) 설명하기", → 화행
          "morpheme": "A/SL+/SC+영상/NNG+등록기/NNG+예다/JKB+등록/NNG+을/JKO+하/VV+고/EC+진료/NNG+과르/NNG+가/JKS+심/NR+쇼/NNG" → 형태소 분석
        },
        {
          ...
        }
      ]
    }
  }
]
}

```

그림13| 콜센터 json 파일 형태 예시

- 가공(라벨링) 도구
- 음성 및 전사 데이터를 여러 기능 또는 목적 등으로 세분화 된 프로젝트로 구성하여 데이터 가공 프로젝트를 진행하도록 지원합니다.



그림기 프로젝트 관리

- 작업자 별로 개별 아이디를 부여하여 작업 진행도 및 참여 실적 등 공유를 통해 작업 효율을 상승시킵니다.
- 클라우드 워커의 작업물을 관리자가 직접승인을 통해 1차 검수를 진행하고, 실적을 확인합니다.





그림14 데이터 가공 및 관리(정제)

- 정제와 같은 방법으로 각 작업자에게 아이디를 부여하여 할당량 제공 및 작업 진행도와 참여 실적을 공유합니다.
- 클라우드 워커의 작업물(라벨링)을 관리자가 2차 검수합니다.




그림15] 데이터 가공 및 관리(라벨링)

● 검수 절차




그림16] 데이터 검수 절차

● 검수 절차 정의

- 다량의 데이터를 한정된 시간 내에 최적의 품질로 검사할 수 있도록 하는 검사 단계 및 절차를 수립
- 검사 프로세스는 학습용 데이터 구축 공정(획득, 정제, 라벨링) 각 단계별로 검사가 수행되는 형태를 기본으로 하며, 데이터 구축 공정 및 데이터 특성을 반영하여 적합한 절차를 수립




그림1기 세부 검수 절차

● 검수 기준

- 검사 항목 정의

- 구축 공정(획득, 정제, 라벨링)별로 공통적으로 적용할 수 있는 검사 요구사항을 고려 하여 검사 항목을 정의
- 검사 항목은 데이터 및 절차 측면에서 적합성·정확성·유효성, 준비성·안전성·유용성 지표를 측정

- 항목별 세부 검증 계획서

- 검증을 정상적으로 수행하기 위한 모든 요소(환경, 도구, 조건 등)가 명확하게 정의 및 마련되어 있어야 하며, 유효성 검증의 경우는 인공지능 학습 개념과 관련된 조건들이 추가로 정의되어야 한다.
- 검증을 위해 세부적으로 수행할 절차를 수립하고, 각 절차별 확인 방법을 구체적으로 작성한다.
- 세부 절차는 앞, 뒤 관계가 논리적으로 전개되어야 하고 시작부터 끝까지의 수행을 통해 목적하는 결과를 확인할 수 있어야 한다.

● 검수 도구

- 도메인 수집량 검수 도구 : 음성파일에 기초하여 전사 텍스트를 발화자 단위로 분리하고, 도메인 정보 추출을 통해 파일명 파싱 후 수집량을 측정하여 검수
- 발화자 성별 검수 도구 : 전사파일에 기초하여 발화자의 성별이 제대로 작성되어 있는지 검수
- 어노테이션 정확도 검수 도구 : 전사파일에 기초하여 #@ 모름#으로 표기하여 정확도 검수