
캡슐내시경 AI 데이터

AI data of capsule endoscopy



건양대학교병원

**해당 자료는 AI-Hub에서 제공된 것으로,
저작권은 AI-Hub에 있으며,
원본 자료는 AI-Hub 웹사이트에서 확인하실 수 있습니다.**

[https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=2
&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&s
earchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORD
ER001&srchPagePer=60&srchDataRealmCode=REALM006&aihu
bDataSe=data&dataSetSn=503](https://www.aihub.or.kr/aihubdata/data/view.do?pageIndex=2&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=&srchDetailCnd=DETAIHCND004&srchOrder=ORDER001&srchPagePer=60&srchDataRealmCode=REALM006&aihubDataSe=data&dataSetSn=503)

ABOUT THIS REPORT

개요

캡슐내시경 AI 데이터는 캡슐내시경 검사로 획득된 영상에서 소장 병변과 장기 위치(위-소장-대장 구간) 정보를 학습할 수 있도록 구축한 의료 영상 데이터셋입니다. 원천 데이터는 이미지/영상 파일(jpg, mpg, avi)로 구성되며, 라벨 데이터는 JSON 형식으로 제공됩니다. 소장 구간에서 관찰되는 궤양·출혈·협착·종괴·림프관 이상 등 다양한 소견과, 위/소장 이행부 및 소장/대장 이행부 등 위치 판별에 필요한 구간 데이터를 포함합니다.

데이터셋 목적

본 데이터셋은 캡슐내시경 영상에서 소장 병변을 조기에 검출(Detection) 하고, 영상이 위치한 장기 구간을 판별(Classification) 하는 AI 모델 개발을 지원하는 것을 목적으로 합니다. 캡슐내시경은 프레임 수가 방대해 의료진이 직접 판독할 때 시간 부담이 큰 검사로, 인공지능 판독 알고리즘을 통해 판독 소요 시간을 줄이고 정확한 판독을 보조하는 활용을 기대합니다. 나아가 임상에서 응용 가능한 판독 시스템 프로토타입 구축 및 내시경 검사 활성화 등 실제 서비스 적용을 염두에 둔 데이터셋입니다. 특히 크론병 등 염증성 장질환 및 출혈성 질환의 조기 발견·평가·치료 지원을 위한 다양한 병변 분류 알고리즘 개발에 활용될 수 있도록 구성하였습니다.

데이터 구축 과정

데이터는 양산부산대학교병원 총괄 하에 다수(12개) 의료기관이 참여하여 캡슐내시경 원천 영상을 수집·정제하고, 가공(라벨링/어노테이션) 및 전문의 검수를 거쳐 구축되었습니다. 수집된 캡슐내시경 영상은 장기 구간의 시작점(예: 유문 통과 후 소장 시작 등) 위치를 확인한 뒤, 전용 판독 소프트웨어를 이용해 프레임 이미지 데이터를 추출·내보내는 방식으로 원천 데이터를 확보합니다(Pillcam은 RAPID Reader, Mirocam은 MiroView 기반 변환/추출). 이후 정제 단계에서 중복 이미지, 정지화면이 장시간 지속되는 구간, 촬영 종료 구간 등 학습에 부적합한 데이터를 삭제·정리하며, 비식별화가 완료된 영상만 정제 대상으로 삼습니다. 가공 단계에서는 병변(5종) 및 장기 위치(4종) 라벨 체계에 따라 어노테이션을 수행하고, 라벨 정보는 JSON 규약에 따라 저장되도록 구축하였습니다.


데이터 검수

검수는 단계별 기준에 따라 수행하며, 1차(획득)에서는 영상 훼손·중복·분할·표기오류 등 기본 품질과 데이터 누락 여부를 확인합니다. 2차(정제)에서는 병변 및 위치 정보 추출이 가능한 상태로 정제가 되었는지 점검하며, 병변(궤양·종양·용종·협착·림프관확장·출혈·혈관확장)과 위치(위, 소장 시작구간, 소장 끝구간, 대장)의 판별 기준을 기반으로 정제 결과의 타당성을 확인합니다. 라벨링 이후에는 검수팀이 일 단위로 레이블 품질을 점검하고 수정·재검수를 반복하여 오류를 최소화하며, 최종 확정된 데이터만 딥러닝 학습용 데이터셋으로 제공합니다. 또한 검수는 참여 의료기관의 소화기내시경 전문의 검수 체계를 기반으로 수행되도록 구성되어 있습니다.

문의처

데이터에 대한 문의 사항은 다음 연락처로 연락주시기 바랍니다.

- 담당자명: (주)서르
- 전화 : 070-5066-0525
- E-mail : seoreu@seoreu.com
- 홈페이지 : www.aihub.or.kr

예시	데이터 항목	JSON 형식
이미지 	병변 - 궤양 - 용종/종양 - 협착 - 림프관확장 - 출혈 혈관확장	<pre> version: "4.2.7" flags: {} shapes: 0: label: "08_intestineSF" points: 0: 0: 541.7272727272727 1: 32.33333333333333 1: 0: 31.121212121212125 1: 32.33333333333333 2: 0: 31.121212121212125 1: 544.4545454545454 3: 0: 541.7272727272727 1: 544.4545454545454 group_id: null shape_type: "polygon" inner: null flags: [] imagePath: "01_01_0001_010709.0.jpg" imageData: "/73/4AAQ2kZ2RgABAAQAB_FABBBQABUUAFFFFFh/9u=" imageHeight: 576 imageWidth: 576 Clinical Information: age: 7 height: 152 weight: 48 gender: "Female" </pre>
영상 	위치 - 위 - 소장시작 - 소장종료 - 대장	연속프레임 한 이미지당 병변 2개 이상 또는 한 이미지당 병변 1개라도 구간내 병변이 2개 이상인 영상

- 원천데이터: 원시데이터(mpg)를 5 frame 단위로 이미지컷을 통해 원천데이터(jpg) 생성
- 라벨데이터: 라벨데이터는 .json 파일로 생성되며 labeling tool을 통해 작업

00:12:51

```

{
  "version": "4.2.7",
  "flags": {},
  "shapes": [
    {
      "label": "01_ulcer",
      "points": [
        {
          "x": 101.03450213256482,
          "y": 219.5965417047435
        },
        {
          "x": 31.87031700280102,
          "y": 219.5965417047435
        },
        {
          "x": 31.87031700280102,
          "y": 329.6104430040346
        },
        {
          "x": 101.03450213256482,
          "y": 329.6104430040346
        }
      ]
    },
    {
      "group_id": null,
      "shape_type": "polygon",
      "inner": null,
      "flags": {}
    }
  ],
  "imagePath": "01_01_0002_010333_4.jpg",
  "imageData": "/9j/AAQcK2mgAAQAAQAAAB/2wC",
  "imageWidth": 576,
  "clinicalInformation": {
    "age": 7.0,
    "height": 151.0,
    "weight": 60.05,
    "gender": "Female",
    "diagnosis": "J.0"
  }
}

```

PillCam® SB2

크리의 원형데이터 / 리벨데이터 예시

● 어노테이션 포맷

● 라벨링 데이터: 병변데이터, 위치데이터

표1| 병변데이터

구분		항목명	타입	필수 여부	설명	범위
1		version	String	M	tool 버전	
2		flags	Float	O	신호	
3		shapes	Object	M	병변 정보	
	3-1	shapes.label	String	M	병변 종류	병변 (01-05)
	3-2	shapes.points	List	M	병변 좌표	2차원
	3-3	shapes.group_id	String	M	그룹	
	3-4	shapes.shape_type	String	M	라벨링 모양	polygon, bunding box
	3-5	shapes.inner	String	O	내부	
	3-6	shapes.flags	Object	O	신호	
4		imagePath	String	M	이미지 이름	
5		imageData	String	M	이미지 정보	
6		imageHeight	Float	M	이미지 세로크기	200-2000
7		imageWidth	Float	M	이미지 가로크기	200-2000
8		clinical information (global)	Object	M	공통임상정보	
	8-1	clinical information (global).age	Float	M	나이	0: 0-10대, 1: 10-20대, 2: 20-30대, 3: 30-40대, 4: 40-50대, 5: 50-60대, 6: 60-70대, 7: 70대 이상
	8-2	clinical information (global).height	Float	O	키 (cm)	100-200
	8-3	clinical information (global).weight	Float	O	몸무게 (kg)	5-150
	8-4	clinical information (global).gender	String	M	성별	Male/Female
	8-5	clinical information (global).diagnosis	Float	M	진단명	1: 크론병 2: 용종 3: 혈관기형 4: 기타

표2| 위치데이터

구분		항목명	타입	필수 여부	설명	범위
1		version	String	M	tool 버전	
2		flags	Float	O	신호	
3		shapes	Object	M	병변 정보	
	3-1	shapes.label	String	M	내시경 위치	위치 (06-09)
	3-2	shapes.points	List	M	병변 좌표	2차원
	3-3	shapes.group_id	String	M	그룹	
	3-4	shapes.shape_type	String	M	라벨링 모양	polygon, bunding box
	3-5	shapes.inner	String	O	내부	
	3-6	shapes.flags	Object	O	신호	
4		imagePath	String	M	이미지 이름	
5		imageData	String	M	이미지 정보	
6		imageHeight	Float	M	이미지 세로크기	200-2000
7		imageWidth	Float	M	이미지 가로크기	200-2000
8		clinical information(global)	Object	M	공통임상정보	
	8-1	clinical information(global).age	Float	M	나이	0: 0-10대, 1: 10-20대, 2: 20-30대, 3: 30-40대, 4: 40-50대, 5: 50-60대, 6: 60-70대, 7: 70대 이상
	8-2	clinical information(global).height	Float	O	키 (cm)	100-200
	8-3	clinical information(global).weight	Float	O	몸무게 (kg)	5-150
	8-4	clinical information(global).gender	String	M	성별	Male/Female

version:	"4.2.7"
flags:	{}
▼ shapes:	
▼ 0:	
label:	"08_intestineSF"
▼ points:	
▼ 0:	
0:	541.7272727272727
1:	32.33333333333331
▼ 1:	
0:	31.121212121212125
1:	32.33333333333331
▼ 2:	
0:	31.121212121212125
1:	544.4545454545454
▼ 3:	
0:	541.7272727272727
1:	544.4545454545454
group_id:	null
shape_type:	"polygon"
inner:	null
flags:	[]
imagePath:	"01_01_0001_010709.0.jpg"
▶ imageData:	"/9j/4AAQSkZJRgABAQAAQAB...FABRRRQAUUUUAFFFFAH/9k="
imageHeight:	576
imageWidth:	576
▼ Clinical Information:	
age:	7
height:	152
weight:	48
gender:	"Female"

그림3| 라벨링데이터 실제예시

● 데이터 구조




그림4| 디렉토리 구조

● 데이터 구축규모

환자 수	총3500명	전체연령	
병변 데이터	300,000장	5개 class	궤양, 용종/중양, 협착, 림프관확장, 출혈 혈관확장
위치 데이터	60,000장	정상 이행부	위/소장 이행부, 소장/대장 이행부
연속 프레임 데이터 (클립 동영상)	40,000장	2개 이상 병변이 존재하는 20초 분량의 연속프레임 데이터	소장
	총400,000장		

그림5| 데이터 구축 규모

● 데이터 분포

● 병변데이터 분포

label	label_count	비율
궤양	261,523	64.4%
용종/종양	25,333	6.2%
협착	15,546	3.8%
림프관 확장	38,956	9.6%
출혈 혈관확장	64,503	15.9%
총합계	405,861	




그림6 병변데이터 범주별 분포

● 위치데이터 분포

label	label_count	비율
06.stomach	15,330	25.2%
07.intestineSS	15,130	24.9%
08.intestineSF	15,340	25.2%
09.intestineL	15,000	24.7%
총합계	60,800	




그림7 위치데이터 범주별 분포

● 원시데이터 특성

● 대상 분류

- 실제 캡슐내시경이 환자의 위, 소장, 대장을 통과하면서 촬영된 이미지

● 제약 조건

- 병변 DB: 소장 구간에 해당되는 이미지만 수집
- 장기위치 DB: 위/소장 이행구간, 소장/대장 이행구간에 해당되는 이미지만 수집

● 속성

- 해상도: 576*576. 320*320
- 초당 프레임수: 2


● 기타 정보

● 포괄성

- 연령 및 성별: 2020년 전체 HIRA(건강보험심사평가원) 데이터와 연령 및 성별 분포가 일치

표3| 연령별 분포

나이	남	여	합계
yr<=10	23	21	44
10<yr<=20	304	150	454
20<yr<=30	279	60	339
30<yr<=40	164	63	227
40<yr<=50	213	112	325
50<yr<=60	298	197	495
60<yr<=70	444	263	707
70<yr<=80	314	323	637
80<yr<=90	107	155	262
90<yr	4	6	10
total	2150	1350	3500



2020년 캡슐 내시경 시행
- HIRA data




그림8| 연령별 분포

표4| 성별 분포

성별	명	%
남	2150	61.4
여	1350	38.6
total	3500	100.0




그림9| 성별 분포

● 다양성

표5| 캡슐 종류별 분포

캡슐 종류	개수	비율(%)
01_SB2	918	26.2
02_SB3	1303	37.2
03_Mirocam	1279	36.5
TOTAL	3500	100.0

● 독립성

- 모든 자료는 각 의료기관의 기관윤리심의위원회의 승인 하에 수집 되었습니다.
- 환자의 의료 영상의 특성상 환자 개인을 특정할 수 있는 지표는 없으나, 지정된 용도 외 사용은 금지됩니다.

● 유의사항

- 데이터 활용은 인공지능 알고리즘을 만들고 검증하는데 있습니다.
- 질환마다 병변의 수가 상이하여 병변 클래스 (5종)의 데이터 분포가 다를 수 있습니다.

● 데이터 구축

● 데이터 구축 목적

- 일반적인 의사의 직접 시행 검사가 아닌 캡슐내시경의 판독은 의사와의 비대면으로 가능할 것으로 예상됩니다.
- 인공지능 판독 알고리즘을 통해 의사의 노동시간을 감소시키고, 사람이 놓칠 수 있는 병변을 인식하고자 합니다.
- 한정된 환자군에게서 선별 되어있는 연구용 데이터셋 편향(bias) 존재의 개연성을 최소화하기 위해 다양한 질환의 환자군, 다양한 연령대 환자군의 영상을 추출, 대량의 데이터셋을 개발하여 의료데이터로서 최적의 real world dataset을 확충할 수 있습니다.

● 데이터 구축 유의사항

- 환자의 의료 영상 데이터로 모든 데이터는 각 의료기관이 기관윤리심의위원회(IRB) 의 승인 하에 수집 되었습니다.
- 구축된 데이터는 개인을 특정할 수 있는 정보가 모두 삭제된 상태로 제공됩니다.
- 수집된 데이터에 대한 개인 정보 보호를 위해 사전절차로 개별 연구자들의 민감 정보 활용에 대한 교육과 승인이 요구됩니다.

● 수집 및 정제

● 수집·정제 절차 및 방법

- 원시데이터 수집 절차
 - 캡슐 내시경 대상자 리스트를 확인하고, 촬영 영상 여부를 확인
 - 영상의 비식별화, 별도의 로그번호 부여
- 비식별화 방법
 - 환자의 영상을 선택하여 이미 판독이 되어진 “findings” 영상 불러오기
 - 캡슐 내시경 판독 프로그램에서 “신원 비표시” 박스를 표시
 - 환자의 입 속에 들어간 영상 이후 영상을 첫 번째 이미지로 “축소 이미지 캡처”
 - “비디오 세그먼트 저장”을 누르면 별도의 로그번호를 통해 지정된 디렉터리에 저장됨
 - 저장된 디렉터리에 별도의 로그번호가 부여된 영상을 프로그램에 실행시켜 완전한 비식별화 확인




그림10이 영상 비식별화 예시

- 원시데이터 정제 절차

- 데이터의 1차 정제 (각 기관): 비식별화, 병변 표시
- 외장형 저장장치에 저장된 1차 정제 데이터를 (썬)서드로 전달
- 서버의 데이터 획득 담당자가 병원에서 비식별화한 정제데이터를 외장하드에 담아 수집하여 서버의 NAS 서버에 저장한 후 외장하드 영상을 삭제
- 영상 데이터를 받은 순서대로 번호를 부여하고, 원시데이터로 저장. 영상에서 추출된 이미지 파일을 저장하고 작업자에게 배부
- 서버에 실시간 저장 및 백업 시행으로 데이터 분실 방지
- 이동 기록 정보를 시리얼 넘버를 부여하여 필요시 추적 가능하도록 함

no	데이터 획득 형태	수집장비	데이터 형식	데이터 처리	담당 인원
1	영상 내 이미지 추출	업체 프로그램	RAW → JPG	데이터 수집 및 라벨링 툴	프로젝트 과제 인력
2	웹 크롤링	크롤링 서버	여러 이미지 포맷 → JPG	데이터 수집 및 라벨링 툴	프로젝트 과제 인력

그림11| 데이터 수집/정제방안 예시

- 원시데이터 정제 방식

가. 정제작업

- 이미지 추출 작업의 파일명 설정
- 저장될 파일명 설정
- 지정된 파일 경로 설정 후 백업

나. 정제 작업 상세

- 추출 프레임 간격 기본 설정은 1초당 1 프레임
- 데이터 부족 시 추출 프레임 간격은 최대 1초당 2 프레임
- 추출한 이미지 파일 저장경로 설정
- 재생 시간 기준으로 파일 이름 생성

● 수집·정제 기준

- 수집 기준

- 캡슐 내시경 영상이 존재하는 환자의 영상
- 제외 기준: 캡슐내시경 영상이 저장되어 있지 않은 경우, 수집 병원 외 기관에서 수행한 영상, 의무기록 확인이 불가능한 경우

- 정제 기준

- 심한 중복 이미지, 캡슐 내시경 촬영 시 지속된 정지 화면, 촬영종료 영상에 관한 데이터 등은 삭제하고 정리하여 라벨링하기 적합한 상태로 유지
- 반드시 비식별화 과정을 거친 영상데이터일 경우에만 정제

● 수집·정제 도구

- Pillcam 영상의 경우 RAPID Reader 프로그램을 사용하여 이미지 데이터 추출
- Mirocam 영상의 경우 MiroView Client 프로그램을 사용하여 avi 변환 후 이미지 데이터 추출




그림12| Rapid 프로그램을 이용한 이미지 데이터 추출 방법

● 가공 및 검사

● 가공(라벨링) 절차 및 방법

- 라벨링 절차

1. Annotation 가공은 수립된 기준으로 작업이 진행됩니다.
2. 가공 전처리로는 새로운 작업자의 경우 트레이닝 1주 후 역량별로 난이도에 맞춰 업무를 배치하고 가공작업이 진행됩니다.
3. 가공된 데이터는 검수팀에서 daily 베이스로 레이블 검수를 진행합니다.
4. 검수 및 수정 완료 데이터는 dataset으로 딥러닝 학습용으로 제공합니다.

* 작업자: 이미지 데이터 확인, 병변 어노테이션 진행.

* 검수자: 병변 어노테이션 검수 후 완료 파일 백업, 전체 어노테이션 데이터 집계 영상별 백업

- 라벨링 방법


- 본 작업은 소장의 병변을 대상으로 진행하는 작업이므로 병변의 형태는 다양하며, 기준에 따라 파악 가능한 병변은 모두 작업하도록 합니다.
- 병변을 감싸는 박스의 크기는 병변보다 작거나 크지 않도록 해야하며, 최대한 여백이 없도록 합니다. 한 프레임에서 병변이 잘 보이지 않더라도 앞뒤 프레임과 비교하여 파악이 가능한 경우 추적하여 라벨링 합니다.
- 부유물이나 그림자 등에 의해 병변이 가려진 부분은 라벨링하지 않습니다.
- 라벨링 할 대상 병변이 없는 프레임은 작업하지 않고 다음 프레임으로 넘어 갑니다.
- 식별가능한 병변은 모두 작업하며, 크기 및 주변 환경을 꼭 확인하고 진행합니다.
- 한 프레임에 여러 개의 병변이 발생하면 동시에 라벨링(바운딩 박스)를 진행합니다.
- 병변의 분류(Class)가 올바른지 확인합니다. (판단이 어려운 경우 필수로 검수자에게 확인 받은 후 진행)

- 가공(라벨링) 기준
- 병변 라벨수: 5가지


표6] 병변 라벨 설명

클래스명	라벨링 기준	기준 설명
01_ulcer (궤양)	염증이나 괴사로 인해 점막의 일부가 없어지거나 함몰된 상태의 병변 (궤양, 아프타 궤양, 미란을 포함한 전체 궤양의 클래스)	크기가 면적 기준 2000pixel 이상인 경우 라벨대상 점막이 70% 이상 보이는 경우 라벨 대상
02_mass (덩어리)	막에서 융기한 병변으로 용종 등을 포함하며 크기는 다양함	크기가 면적 기준 2000pixel 이상인 경우 라벨대상 점막이 70% 이상 보이는 경우 라벨 대상
03_stricture (협착)	소장관강이 좁아지고 있는 상태로 통로 주변에 주름이 없음	크기가 면적 기준 2000pixel 이상인 경우 라벨대상 점막이 70% 이상 보이는 경우 라벨 대상
04_lymph (림프관확장)	융털이 쌀알처럼 흰색을 띄는 경우, 뭉쳐진 림프관확장과 융털 끝의 부종을 모두 포함한 병변	크기가 면적 기준 2000pixel 이상인 경우 라벨대상 점막이 70% 이상 보이는 경우 라벨 대상
05_bleeding (출혈)	출혈: 혈관손상으로 혈액이 혈관 밖으로 나오는 것 혈관확장: 비정상적으로 생긴 혈관 모양	크기가 면적 기준 2000pixel 이상인 경우 라벨대상 점막이 70% 이상 보이는 경우 라벨 대상

- 병변데이터 라벨링 예시(Ulcer-궤양)




흰 부유물이 앞의 초 이미지랑 비교했을 때 움직임이 있으면 부유물로 판단




진행방향 기준으로 궤양 크기따라
½이나 ¼로 나누어 작업

왼쪽 궤양이 확대된 사진



I. 궤양영역을 각각 라벨링함



II. 라벨링 영역이 조금 더 엄격된 듯 보여
이전에 두개로 나뉜 한 부분을 병합해
서 작업함



III. 조금 간격이 있는 부분도 합하여
포함하여 크게 라벨링

실제 궤양은 궤양 중심과 주변 용기부까지임.
주변 용기부까지 생각해야 해서 III. 처럼 라벨링한다.

그림13| 병변데이터(궤양) 라벨링 적용 예시

- 병변데이터 라벨링 예시(Mass-용종/종양)



소장 끝쪽 (말단부 회장, 소장 마지막
50cm 정도)에서 관찰되는 정상적인
림프 결절 증식 (lymphonodular
hyperplasia) 는 용종이 아님.



작은 덩어리의 mass




진행방향부분을 가리고 있는 mass



용종의 연결 부위까지 라벨링

그림14| 병변데이터(용종) 라벨링 적용 예시


- 병변데이터 라벨링 예시(Stricture-협착)



통로가 좁아진 부분만 라벨링한다

그림15| 병변데이터(협착) 라벨링 적용 예시

- 병변데이터 라벨링 예시(Lymphangiectasia-림프관 확장)



화면 전체 라벨링

그림16| 병변데이터(림프관 확장) 라벨링 적용 예시

- 병변데이터 라벨링 예시(bleeding_vascularectasia-출혈 혈관확장)



함몰되며 출혈된 부분

출혈된 부분이 떨어져 움직임

악이 떠다니는 경우, 출혈이 화면 전체적으로 퍼지는 경우는 작업 안함



출혈이 발생한 곳을 찾아주는데, 어두운 검붉은 곳이 출혈시작 부분임.
진행 통로 방향과 구분하여 보기

그림17| 병변데이터(출혈) 라벨링 적용 예시

- 장기위치 라벨수: 4가지

표기 장기위치 라벨 설명

클래스명	라벨링 기준	기준 설명
06_stomach	편평하고 넓은 공간에 주름이 크고 넓게 분포, 유문을 지나기 직전	유문 통과 전 영상은 라벨 대상
07_intestineSS	유문을 지난 후 섬모가 관찰되며 내강이 좁아짐	유문 통과 전 영상은 라벨 대상
08_intestineSF	림프절이 발달되어 있으며, 회맹판을 지나기 직전	소장 섬모가 확인됨
09_intestineL	회맹판을 지나 넓은 공간에 섬모가 관찰되지 않음	소장 섬모가 확인되지 않음

● 가공(라벨링) 도구

- Labelme: Bounding box, Polygon, Polyline, Point 등 다양한 형태의 도형과 Classification, Segmentation 등 다양한 task의 라벨링 지원하는 라벨링 도구

· Program

Labelme 작업 화면




· Work Process

데이터 확보가 필요한 영역에 점을 찍어가며 Labeling을 한다.



· Program

이노데이터전 작업 전 [의료생물] 파일을 열어 라벨목록을 불러온다.




· Work Process

영역 지정을 완료하면 자동으로 오픈되는 라벨창에서 라벨을 선택해준다.



Work Process

작업한 데이터 폴더에 있는 이미지와 같은 파일명으로 Annotation Data 저장한다.



Work Process

이미지가 있는 폴더에 json 파일이 저장되었는지 확인해준다.




그림18| 라벨링 도구 매뉴얼

● 검수 절차

검사 절차	영상(동적/정적) 이미지 공동 항목	요구사항
1차 검사 (획득)	법·제도 준수	원시데이터 획득 시 관련 법·제도적 규정 등을 반드시 준수하여야 함
	데이터 동기화	다중 데이터 소스 간 정교한 동기화를 위한 절차를 마련하여야 함
	편향성 방지	데이터 편향을 방지하기 위한 절차를 마련하여야 함
2차 검사 (정제)	정제 기준의 명확성	데이터 사용 목적에 적합한 정제 기준 수립 여부 검사
	중복성 방지	데이터 정제 후 정보 비교 후 중복도 여부 검사
	정제 작업 매뉴얼	정제 작업을 위한 매뉴얼 작성 및 관리 여부 검사
	정제 도구	정제 작업에 사용될 SW 도구를 확보 및 사용 방법을 숙지
	정제 작업 방식	데이터 특성 및 활용 목적에 맞는 적절한 정제 방식 선정 여부 및 선정 기준 타당성 여부 검사
3차 검사 (라벨링 검수)	라벨링 가이드	목적에 맞게 작성된 라벨링 가이드에 대한 타당성 여부를 검사 후 라벨링 작업자들에게 내용 가이드 전달
	어노테이션 항목	목적에 맞는 어노테이션 구성인지 여부를 검사 후 확인된 내용을 포함하도록 작업자들에게 전달
	라벨링 검사 도구	검사자가 육안으로 부적합 데이터 여부 확인과 촬영된 영상(동적/정적) 이미지의 누락, 번짐 및 조건 오류를 전수 검사
4차 검사 (전수)	부적합 판정 데이터 분포 확인	데이터의 오류율, 특성 분포 확인을 통한 데이터 수집, 정제, 라벨링, 부문 최적화
	외부 검사자	병원 전문의, 외부 검사자(TTA 등), 도메인 전문가, 데이터 요청자

그림19| 검사 절차 요구사항

● 단계별 검수 방법

- 1차 검사(수집)

1. 훼손: 비식별화되지 않은 영상, 즉 환자의 임상정보가 표시되어있는 영상은 재요청
2. 중복: 동일한 영상이 중복되어 수집되는 경우에는 중복 데이터를 제거
3. 분실: 영상이 분실되고 환자정보 CRF 기록만 남아있는 경우, 기록만 수집하고 영상은 분실처리
4. 표기오류: 정상, 비정상, 진단명이 잘못적혀있을 경우 재요청

- 2차 검사(정제)

추출 프로그램을 통하여 소장에 해당하는 부분(약 4시간)을 1초에 1-2frame으로 추출(자동)

→ 병변에 해당하는 부분을 육안검사를 통해 병변 프레임만 추출

- 추출된 분할이미지의 파일명 오류 확인
- 비식별화된 영상과 분할이미지를 비교하여 잘 분할되었는지 확인
- 심한 중복 이미지, 캡슐 내시경 촬영 정지화면의 지속, 촬영종료 영상에 관한 데이터를 정리하여 라벨링하기 적합한 상태로 유지
- 십이지장(소장시작 지점) ~ 맹장(소장종료 지점) 확인 후 병변에 관한 체크표기가 올바르게 되어있는지 확인




그림20이 실제 영상과 분할이미지 비교

- 3차 검사(검수): 전문의 검수 1차

- 육안 검수를 통해 100% 전수 검사로 진행
- 라벨링 검수 → 오류 발견 → 검수자가 라벨링 오류기록 후 작업자에게 피드백 → 작업자 2차 라벨링 → 2차 검사 후 수정된 데이터로 저장

병변_Annotation [Segmentation / labeling] Inspection등록							
검수일자	검수자	전문의1차	물대명	영상명	오류이미지 구간	피드백	검수자 수정여부
2021-08-20	박수현	문상욱	20210702이유정	02_01_0020	3802.2~3802.4	궤양이 희미하므로 식재	수정완료
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3804.6~3804.8	부유물로 가려져있어서 분간이 어려우므로 식재	수정완료
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3806.6	통과	확인
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3808.4~3808.6	궤양 라벨링하기	수정완료
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3810.2~3810.4	통과	확인
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3812.6	니선형 궤양이므로 전체적으로 포함되게 라벨링	수정완료
2021-08-20	박수현	문상욱	20210705이유정	02_01_0020	3813.8~3815.0	통과	확인




그림21| 1차 검수 로그

- 4차 검사(검수): 전문의 검수 2차

(라벨링 검사가 끝난 데이터를 주관기관의 실무책임자가 1차 검수 → 각 병원 책임자에게 전달) → 소화기내시경 전문 검수인력에 의한 2차 검수, 임상정보 융합 → 주관수행기관의 실무책임자에게 전달 → 최종 데이터 검수

병변_Annotation [Segmentation / labeling] Inspection등록							
검수일자	전문의1차	전문의2차	영상명	오류이미지 구간	피드백	서브 수정여부	문상욱교수님
2021-09-17	문상욱	박수현	01_01_0019	003035.8 ~ 003109.4	통과		확인
2021-09-17	문상욱	박수현	01_01_0019	003131.6	통과		확인
2021-09-17	문상욱	박수현	01_01_0019	004835.0 ~ 004835.2	통과		확인
2021-09-17	문상욱	박수현	01_01_0019	010043.0 ~ 010043.2	병변에 맞게 라벨링하게 배정해주실 수월하길		확인
2021-09-17	문상욱	박수현	01_01_0019	010043.6	통과		확인
2021-09-17	문상욱	박수현	01_01_0019	010045.0 ~ 010045.6	통과		확인




그림22| 2차 검수 로그

- 검수 기준
- 1차 검사(획득) 검사항목

표8| 1차 검사 기준

구분	검사항목	기준
영상품질	훼손	육안에 의한 판독 가능여부 확인
	중복	동일 영상 확인
	분실	영상이 존재하는지 확인
	표기오류	판독결과 및 진단명 확인

- 2차 검사(정제) 검사항목: 병변 추출

표9| 2차 검사 기준(병변)

구분	병변종류	기준
병변	ulcer(궤양)	염증이나 괴사로 점막, 각막, 피부의 일부가 없어지거나 함몰된 상태의 병변
	mass(용종/종양)	막에서 융기한 병변으로 용종 등을 포함하며 크기는 다양함
	stricture(협착)	소장관강이 좁아지고 있는 상태로 통로주변에 주름이 없음
	lymph(림프관확장)	용털이 쌀알처럼 흰색을 띄는 경우 이상증상임
	bleeding(출혈_혈관확장)	- 출혈: 혈관손상으로 혈액이 혈관 밖으로 나오는 것 - 혈관확장: 비정상적으로 긴 혈관 모양

- 2차 검사(정제) 검사항목: 위치 정보 추출

표10| 2차 검사 기준(위치)

구분	위치	기준
위치	Stomach(위)	편평하고 넓은 공간에 주름이 크고 넓게 분포, 유문을 지나기 직전
	small intestine s(소장 시작구간)	유문을 지난 직후 섬모가 관찰되며 내강이 좁아짐
	small intestine f(소장 끝 구간)	림프절이 발달되어 있으며, 회맹판을 지나기 직전
	large intestine(대장)	회맹판을 지나 넓은 공간에 섬모가 관찰되지 않음.

- 2차 검사(정제) 검사항목: 병변을 2개 이상 포함한 20초 이상의 연속된 영상 추출

표11| 2차 검사 기준(연속)

구분	위치	기준
연속된 프레임영상	Small intestine (소장)	어노테이션된 병변을 2개 이상 포함한 20초 이상의 연속된 프레임의 영상

- 3차 검사(라벨링) 검사항목: 전문의 검수 1차

표12| 3차 검사 기준

구분	검사항목	오류내용
작업오류	미작업	미작업된 라벨
	부분오류	다른 영역 포함 , 해당 영역 미포함 등
	라인오류	Boundingbox 변형
	라벨삭제	중복 라벨 , 불필요 라벨
	명칭오류	라벨 이름 오류

- 4차검사(전수) 검사항목: 전문의 검수 2차
 - 어노테이션 오류 검수 : 양산부산대 포함 12개 참여기관. 참여한 소화기내시경 전문의사에 의한 육안 검사
 - 기타 데이터 품질 검수 : 데이터의 오류, 분포등에 대한 적합성 검수 진행
 - 가장 많이 확인될 것으로 생각되는 01_ulcer와 05_bleeding의 경우
 - 1) 다양한 환자로부터
 - 2) 고해상도영상 우선
 - 3) 동일 병변 3개 초과 중복되지 않도록
 - 4) 면적 기준 2000 pixel 이상의 임상적으로 의미있는 병변 위주로 수집
- 주관기관에서 실무책임자에 의해 선별
- 영상의 수가 상대적으로 적은 병변은 가능한 한 전수 확보하여 데이터 편향성을 예방
- 심한 이물질, 부유물, 거품 등으로 병변이 명확히 확인되지 않는 경우는 검수자의 주관적인 판단 하에 제외할 예정 (전체 면적의 70% 이상 점막이 관찰되지 않는 경우. 전문의 2인의 육안검수 일치하도록 판정)
- 검수 도구
 - 데이터 저작 도구와 동일한 도구 사용